Machine Learning

Módulo 2

EDUCACIÓN IT

Outliers

Outliers

Es un valor atípico que difiere significativamente del resto de las instancias.

- Los datos con los que se está trabajando pueden no ser homogéneos.
  - Transacciones fraudulentas con tarjetas de crédito.
  - Estudios médicos realizados sobre personas sanas y enfermas con muy bajo grado de incidencia de la enfermedad.
- Puede haber un error en la carga de los datos.
  - Error humano en la digitación de los datos.
- Puede haber un error en la medición de los datos.
  - Error en transferencia de datos.
  - Problemas de ajustes con aparatos de medición.

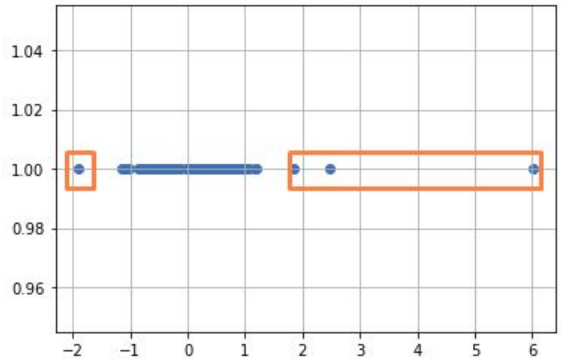


Outliers

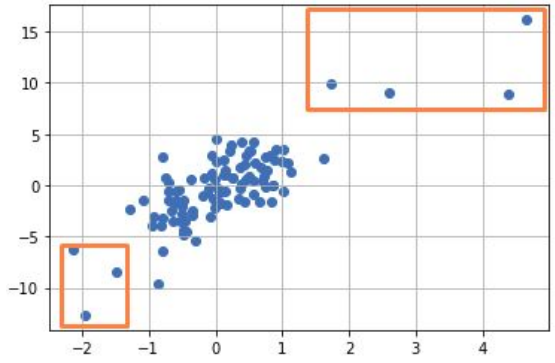
Esos valores atípicos suelen confundir la estadística que hacemos sobre los datos, ya que nos indican que no estamos trabajando con muestras homogéneas.

Tipos de valores atípicos:

- **Univariante:** Es una desviación de los valores típicos sobre una columna de los datos:



- **Multivariante:** Es una desviación en la relación entre dos o más columnas de los datos:



Detección de outliers

No hay una manera evidente de detectar outliers, siempre depende del problema con el que estemos tratando. Hay varios métodos para hacerlo, sin embargo, qué hacer con esta información depende en gran medida de la situación.

A veces es apropiado excluir los valores atípicos de un conjunto de datos para hacer que un modelo entrenado en ese conjunto de datos sea más predictivo. A veces, la presencia de valores atípicos es una señal de advertencia de que el proceso del mundo real que genera los datos es más complicado de lo esperado.

- Rango intercuartílico.
- Visualización: Diagramas Boxplot.
- Regla de las tres sigmas.

Enlace recomendado:
http://colingorrie.github.io/outlier-detection.html

Detección de outliers

Rango Intercuartílico

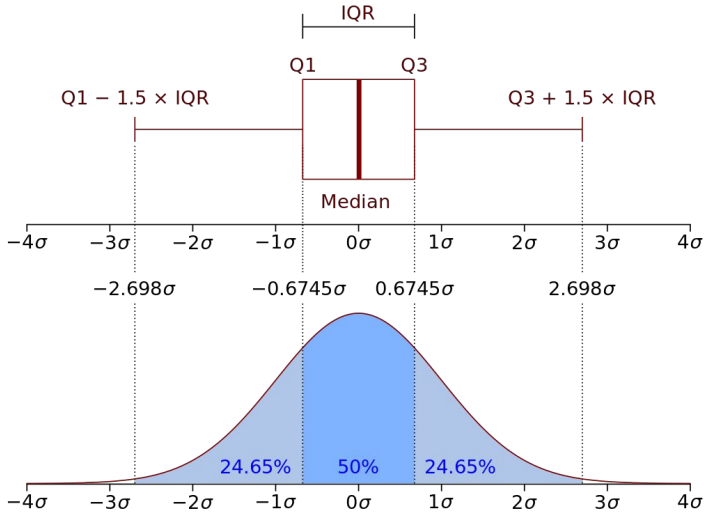
Se elige un valor mínimo y uno máximo para los valores “permitidos”. Marcamos como outliers aquellos valores que estén por debajo del mínimo o por arriba del máximo.

Por ejemplo, la cantidad de ventas de un artículo no puede ser menor que cero ni mayor al stock.

Un criterio estandarizado es usar:

- mínimo = Q1 - 1.5 x IQR
- máximo = Q3 + 1.5 x IQR

Hasta Q1 se encuentran el 25% y hasta Q3 el 75% de los datos, entonces, entre Q1 y Q3 se encuentran el 50% de los datos.

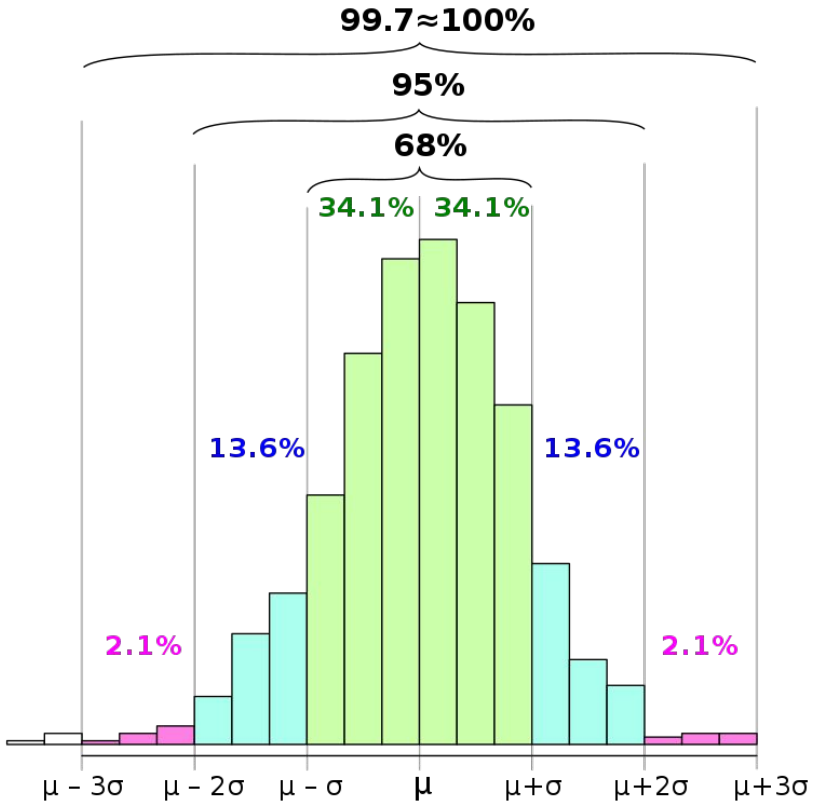


Detección de outliers

Boxplot

El diagrama de cajas es una forma de visualizar un conjunto de valores.

Muchas veces resulta más informativo que simplemente dibujar un punto por cada valor, ya que nos permite tener una idea de cómo es la distribución subyacente.



Detección de outliers

Regla de las tres sigmas

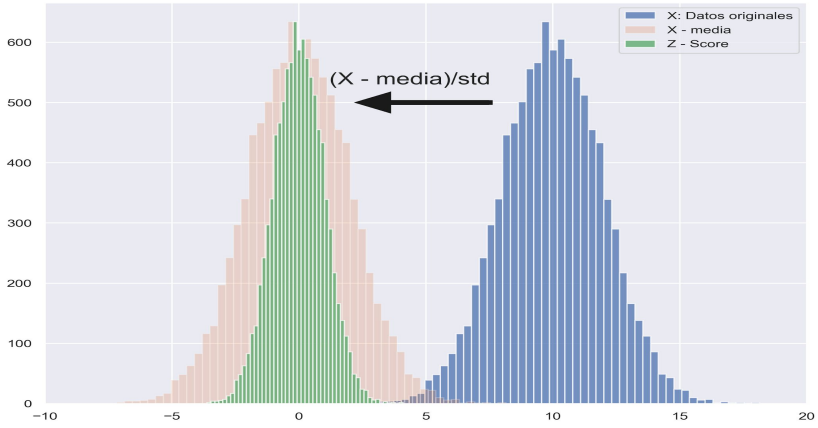
Se utiliza la desviación estándar, donde el valor mínimo y el máximo quedan definidos de la siguiente forma:

- mínimo = valor medio - 3 x SD
- máximo = valor medio + 3 x SD

Los valores que estén a distancia mayor a tres desviaciones estándar de la media son seleccionados como outliers.

Valor		Z-Score
1	(1-2.5)/1.12	-1.34
2	(2-2.5)/1.12	-0.45
3	(3-2.5)/1.12	0.45
4	(4-2.5)/1.12	1.34

- Promedio: 2.5
- Desviación estándar: 1.12

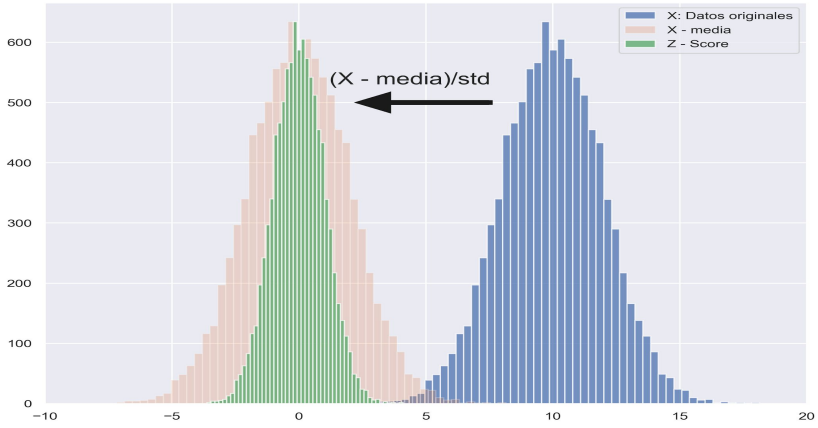


Detección de outliers

A veces este método se aplica a través del **z-score**, que consiste en dado un conjunto de números, su media y su desviación estándar. Cada valor es reemplazado por la cantidad de desviaciones estándar en que se aleja de su media, es el método conocido StandardScaler de Scikit-Learn:

Valor		Z-Score
1	(1-2.5)/1.12	-1.34
2	(2-2.5)/1.12	-0.45
3	(3-2.5)/1.12	0.45
4	(4-2.5)/1.12	1.34

- Promedio: 2.5
- Desviación estándar: 1.12



Outliers - varianza

En ocasiones el valor de la varianza puede ser **demasiado alto** cuando, por ejemplo, se trabaja con **muestras pequeñas** o bien, la muestra se puede agrupar en muestras más chicas que tengan una distribución Gaussiana, hecho que no se visualiza sobre el total. En Estadística esto se conoce como **mezclas Gaussianas**.

Hay que tener mucho cuidado al afirmar que hay una mayor (o menor) incidencia de un efecto en alguna de esas muestras por encima de lo esperado.

En general, para poder decir que existe un fenómeno de este tipo, vamos a tener que cuantificar que la desviación encontrada está por encima de lo esperado.

Y es muy útil, además, una relación causal que pueda explicar el fenómeno que estamos viendo. Esto dependerá de las características específicas de cada problemática, en general, son problemáticas multicausales y existe un riesgo de caer en explicaciones simplistas o, directamente, erróneas.

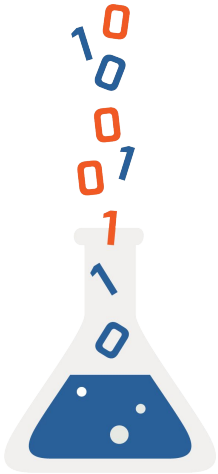
Visualización de gráficos

Los gráficos son una herramienta tanto de análisis en una etapa de exploración del dato, como de comunicación de conclusiones, que permiten compartir información de forma que ésta se comprenda mejor que los números mismos.

Hay algunas pautas que son de considerar a la hora de graficar:

- Hacerlo auto-explicativo y simple, de forma de no requerir una explicación por parte de su autor.
- Mostrar claramente las unidades en las que están expresados los valores y que las mismas comiencen en cero, o bien no distorsionen la proporcionalidad.
- Hacerlo de la manera más limpia posible. No debe haber demasiados colores en los ejes, las series, o cualquiera de sus elementos. Evitando así la distracción.

Enlace recomendado:
https://www.youtube.com/watch?v=E91bGT9BjYk



Lab Time!

¡Muchas gracias!

¡Sigamos trabajando!