Machine Learning

Módulo 1

Flujo de trabajo

Flujo de trabajo en Machine Learning

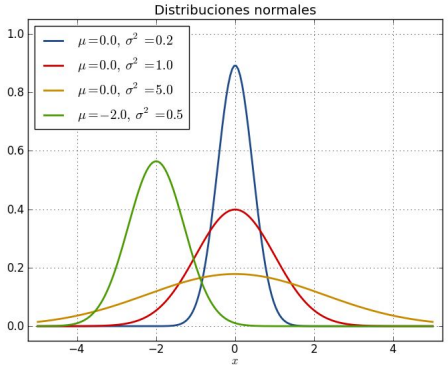


- **Definición:** Se definen las preguntas que queremos responder. ¿Qué datos necesitamos para responder esas preguntas?
- **Investigación:** Se obtienen los datos, se "limpian" y se procede a explorarlos.
- **Análisis:** Los datos obtenidos se analizan con modelos (estadísticos, Machine Learning, etc.). Interpretamos los resultados y transformamos datos en información.
- **Presentación:** Presentamos los resultados obtenidos y las conclusiones a las que llegamos. La información se transforma en Conocimiento. Puesta en producción.

Exploración de los datos

Los datos con los que vamos a estar trabajando, son en definitiva la **fuente del conocimiento** necesario que debemos adquirir para poder resolver las preguntas que nos hacemos, entonces, es preciso conocer todas sus características, algunas de ellas son:

- Variabilidad.
- Estadística.
- Distribución.
- Rangos.





Falencias en los datos

Como primera medida, antes de comenzar a realizar las tareas de análisis, vamos a encontrarnos con ciertas cuestiones que hacen a la **calidad y fiabilidad** del dato, y debemos resolverlas, entre ellas:

- **Faltantes**: ¿Qué hacer?
- **Rangos** de datos numéricos.
- **Normalización.**
- **Errores**: Su tratamiento.





Datos cualitativos y cuantitativos

Es importante reconocer los diferentes tipos de datos: numéricos (discretos y continuos) y categóricos o cualitativos.

Denominaremos **variable** a cada columna en nuestro **conjunto de datos o dataset**. Tendremos entonces dos tipos de variables:

- **Cualitativas**:
  Que reflejaran una categoría, son etiquetas alfanuméricas o “nombres”. Pueden ser nominales u ordinales.
- **Cuantitativas**:
  Que reflejaran un valor numérico, que puede ser discreto o continuo.



número de edición



especies de flores



cantidad de goles



temperatura

Variables cualitativas

Nominales: Sus posibles valores pertenecen a una o varias **categorías**.

- Las categorías no siguen una relación de orden.
- Ninguna es mayor o menor que otra.

Ejemplos:

- Nacionalidad
- Tipo de Vino
- Especies de flores
- Color de auto

Tratamiento:

- Llevar a **variables dummies** con One-Hot Encoding. La variable dummie será entonces aquella que tome valores 0 o 1, en función de la presencia o no de un atributo.
- Puede hacer que nuestro dataset crezca mucho.

Obs.	Ciudad
1	Rosario
2	Buenos Aires
3	Rosario
4	Mar del Plata
5	Córdoba

Obs.	D_BA	D_C	D_R
1	0	0	1
2	1	0	0
3	0	0	1
4	0	0	0
5	0	1	0

Variables cualitativas

Ordinales: Sus posibles valores son categorías pero sí hay una **relación de orden**. A pesar de que pueden ser números, ¡no se deben sumar!

Ejemplos:

- Tamaño de una prenda de ropa: XS, S, M, L, XL
- Tipo de Nafta por octanaje: 95, 98, más de 98.
- Rangos etarios: bebé, niño/a, adolescente, adulto/a, anciano/a

Tratamiento:

- Podemos hacer una asignación a número enteros manteniendo el orden:
  - S → 0
  - M → 1
  - L → 2

Variables cuantitativas

Numéricas: Son aquellas variables que se miden o se cuentan. Pueden ser **discretas o continuas**.

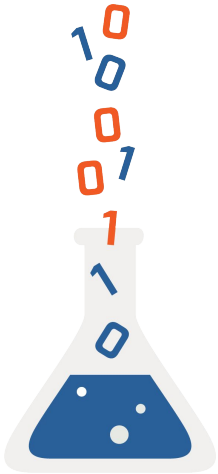
- Hay una relación de orden entre ellas.
- Se puede aplicar **funciones de agregación**.

Ejemplos:

- Edad, Altura y Peso.
- Puntaje, precio de un vino.
- Valor de un pasaje.

Tratamiento:

En general, ya vienen en un formato “cómodo” para trabajar, pero a veces queremos agruparlas según grupos o rangos, por ej.: agrupar edades en rangos (bebés, niños, adolescentes, adultos, ancianos), esto se denomina: **Discretización y Binning**



Lab Time!

¡Muchas gracias!

¡Sigamos trabajando!