Machine Learning

Módulo 2

EDUCACIÓN IT

Probabilidad y estadística

Probabilidad y estadística

Probabilidad: Lo que se espera que suceda. Se arman modelos sobre la naturaleza del problema, apoyados en la Combinatoria. Por ejemplo, ¿qué probabilidad tengo de obtener dos 6 al tirar dos dados?

> Hay 6 x 6 posibilidades distintas, de entre ellas solo 2 darán como resultado dos 6, así que la probabilidad es de 2 entre 36, es decir 1/18.

Estadística: Lo que sucedió. ¿Tiene sentido con mi modelo? Luego de arrojar 100 veces 2 dados, ¿qué resultados obtuve?



Enlace recomendado:
https://seeing-theory.brown.edu/es.html

Probabilidad

- Probabilidad **Frecuentista**: Si hacemos un experimento muchas veces, la probabilidad está asociada a la frecuencia con que ocurre cada posible valor de la variable aleatoria.
- Probabilidad **Bayesiana**: medida de la confianza o certidumbre de que un suceso ocurra. La mejor medida de la incertidumbre es la probabilidad.
- La **variable aleatoria** (X) son los posibles resultados de un proceso aleatorio:
  - Xmoneda : (cara, ceca)
  - Xdado: (1,2,3,4,5,6)



Probabilidad

Variables aleatorias

- Variables **Continuas**:
  - Son aquellas que **se miden.**
  - Pueden estar acotadas o no.

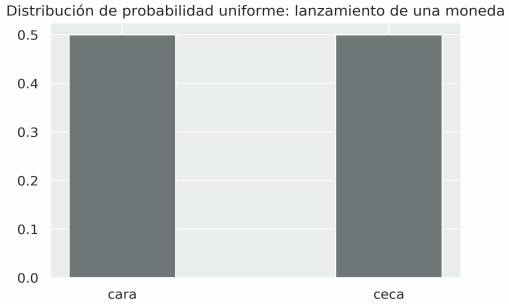
  Ejemplo: Altura de una persona, temperatura, velocidad, etc.

- Variables **Discretas**:
  - Son aquellas que **se cuentan.**
  - Pueden estar acotadas o no.

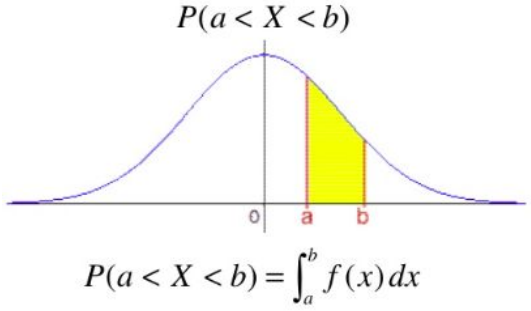
  Ejemplo: Edades (en años), número de hijos, cantidad de dormitorios de una casa, etc.

Distribución de probabilidad

- La distribución de la probabilidad en una variable discreta es una función que asigna a cada suceso definido sobre la variable la probabilidad de que dicho suceso ocurra.



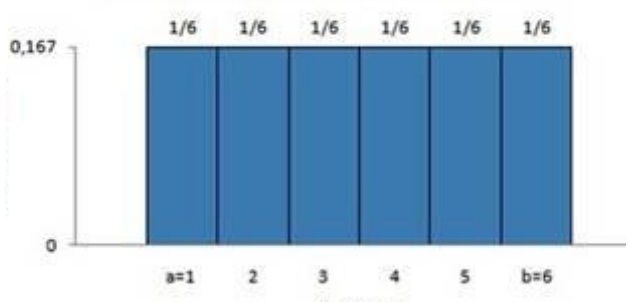
- Para variable continua, hablamos de la probabilidad de que tome un valor en el intervalo medido entre dos puntos del rango.



Distribución de una variable discreta

Uniforme: Asigna la misma probabilidad para todo un rango de valores.

Ejemplo del dado: P(X = 1, 2, 3, 4, 5, 6) = 1/6



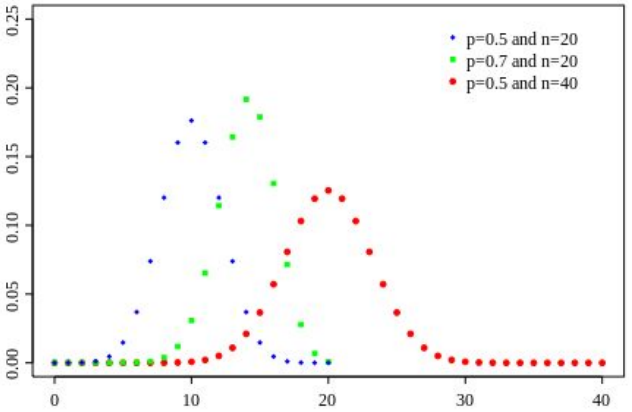
Distribución de una variable discreta

Binomial: Imaginemos que tiro “n” veces una moneda con probabilidad “p” de sacar cara (o ceca), ¿cuál sería la probabilidad de sacar “x” caras (o cecas)? Esta distribución responde a esa pregunta.

$$f(x) = \binom{n}{x} p^x (1-p)^{n-x}, \quad 0 \leq p \leq 1$$

donde $x = \{0, 1, 2, \ldots, n\}$

Combinatoria: $\binom{n}{x} = \frac{n!}{x!(n-x)!}$



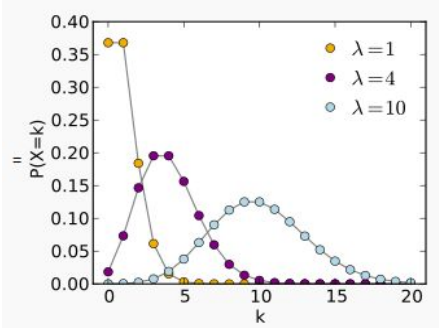
Distribución de una variable discreta

Poisson: Describe la probabilidad de “k” cantidad de eventos en cierto intervalo de tiempo. Por ejemplo, número de inundaciones en una ciudad por año.

Se especializa en la probabilidad de ocurrencia de sucesos con probabilidades muy pequeñas:

$$f(k,\lambda) = \frac{e^{-\lambda}\lambda^{k}}{k!}$$

λ es un parámetro positivo que representa el número de veces que se espera que ocurra el fenómeno durante un intervalo dado. Si el suceso estudiado tiene lugar en promedio 2 veces por año y estamos interesados en la probabilidad de que ocurra k veces dentro de un intervalo de 5 años, usaremos un modelo de distribución de Poisson con λ = 5 ×2 = 10.
El eje horizontal es el índice x. La función solamente está definida en valores enteros de k. Las líneas que conectan los puntos son solo guías para el ojo y no indican continuidad.



Distribución de una variable discreta

Existe el concepto de **esperanza, esperanza matemática** o **valor esperado** que se define como:

Sea X una variable aleatoria cuya distribución es P(x):

$$E[X] = \sum_{x \in X} x P(x)$$

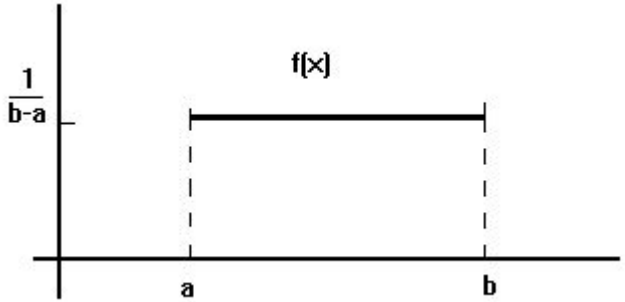
Es un valor promedio pesado/ponderado, veamos el ejemplo de los dados, donde la esperanza, para el tiro de un dado, es 3.5:

$$\mathrm{E}[X] = 1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{6} + 3 \cdot \frac{1}{6} + 4 \cdot \frac{1}{6} + 5 \cdot \frac{1}{6} + 6 \cdot \frac{1}{6} = 3.5$$

Distribución de una variable continua

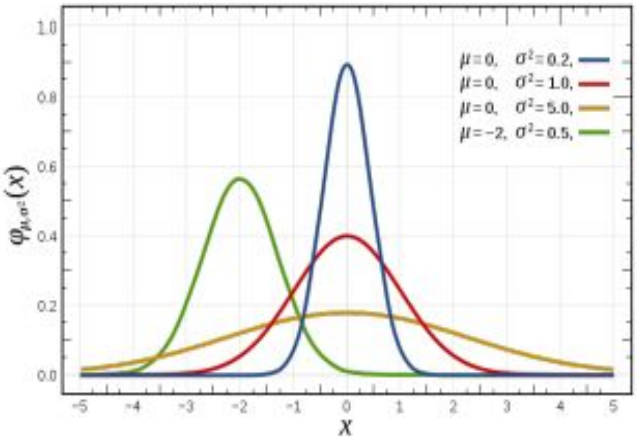
La distribución o modelo **uniforme** puede considerarse como proveniente de un proceso de extracción aleatoria. El planteamiento radica en el hecho de que la probabilidad se distribuye uniformemente a lo largo de un intervalo. Así, dada una variable aleatoria continua x, definida en el intervalo [a,b] de la recta real, diremos que x tiene una distribución uniforme en el intervalo [a,b] cuando su función de densidad para:

$$x \to U[a,b] \text{ sea: } f(x) = \frac{1}{b-a} \text{ para x} \in [a,b].$$



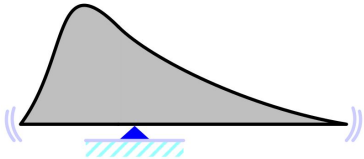
Distribución de una variable continua

- La distribución Normal, o **Gaussiana,** es la más conocida y se manejan los conceptos de valor medio, media o promedio de los datos y desviación estándar.
- En esta distribución en particular, el promedio, la mediana y la moda tienen el mismo valor.
- La **desviación estándar** consiste en:
  1. Calcular la media.
  2. Calcular el cuadrado de la distancia a la media para cada dato.
  3. Sumar los valores que resultaron del paso 2.
  4. Dividir entre el número de datos (hasta aquí obtuvimos la **varianza**).
  5. Sacar la raíz cuadrada.

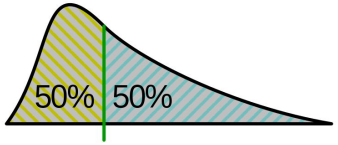


Distribución de una variable continua

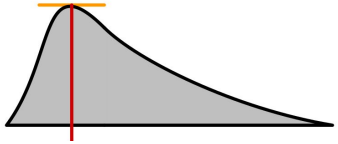
- La **media o promedio** es la suma de los valores sobre la cantidad de valores.



- La **mediana**, es el valor que ocupa el lugar central de todos los datos, cuando estos están ordenados de menor a mayor.



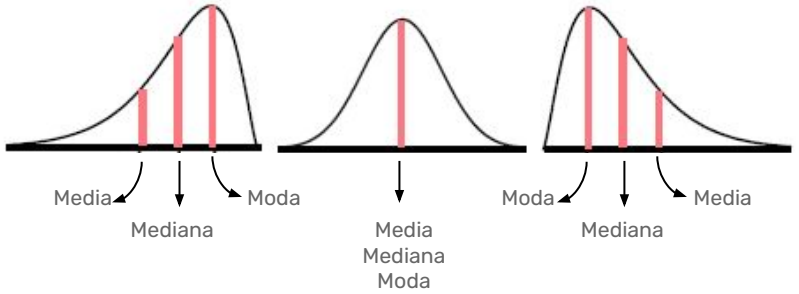
- La **moda** es el valor que más se repite.



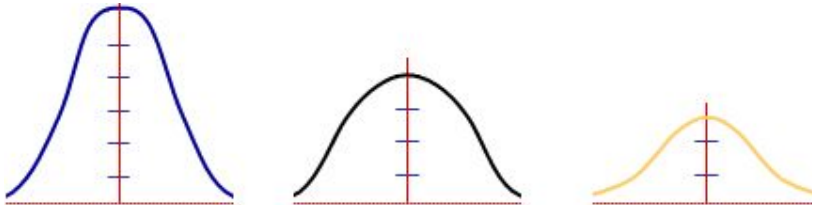
Asimetría y curtosis

En una distribución de probabilidad Normal o Gaussiana, tenemos que los valores de media, moda y mediana son iguales, pero puede ocurrir que no sea así, y la distribución no sea simétrica presentando una asimetría a derecha o izquierda.

Por otra parte, puede haber simetría y, sin embargo, que la distribución sea más o menos densa, alargando o achicando la varianza.



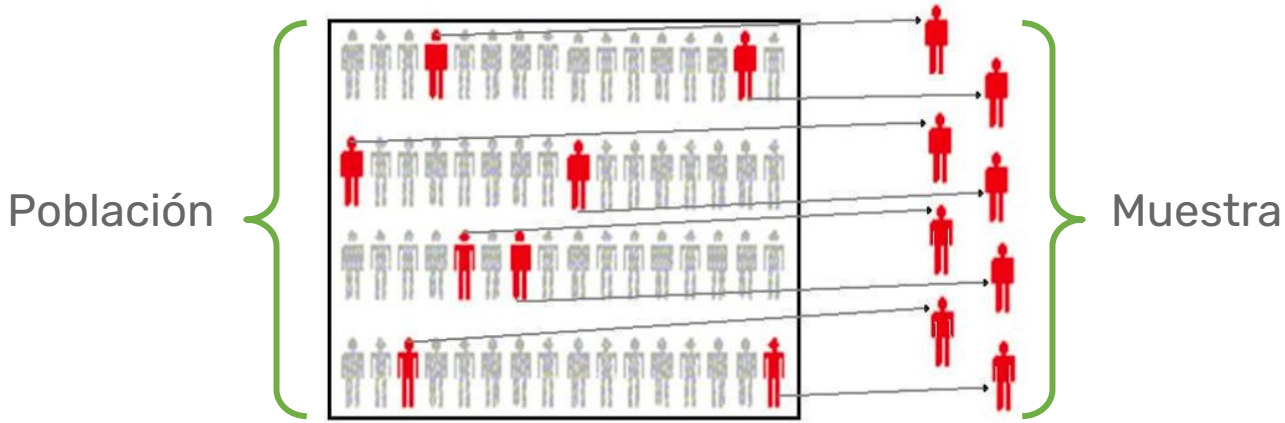
Asimétrica hacia la izquierda | Simétrica | Asimétrica hacia la derecha



Leptocúrtica | Mesocúrtica | Platicúrtica

Población y muestra

La **población** de un estudio estadístico es el conjunto de elementos objeto de estudio. Cada elemento se denomina individuo. Cuando el número de individuos de la población es muy grande, tomamos una parte de ésta, denominada **muestra**. La muestra es un subconjunto de la población y tiene que ser representativa de la misma.



Correlación entre variables

Eventualmente vamos a querer conocer si existe una relación entre dos o más variables de un dataset, entendiendo por relación a una "variación conjunta". Si este es el caso, podríamos ver que si una de las variables aumenta o disminuye su valor, que la otra también lo hace. La **covarianza** es una medida que intenta cuantificar esa relación.

$$Cov(X,Y) = \frac{\sum_1^n (x_i - \bar{x})(y_i - \bar{y})}{n}$$



Correlación entre variables

Con la covarianza también podemos determinar el coeficiente de relación o la recta de regresión, pero tiene el inconveniente de depender de la escala de los datos, motivo por el cual definimos la **correlación,** que es la covarianza dividida la desviación estándar de cada variable aleatoria obteniendo un valor que va de -1 a 1. Donde:

$$r_{xy} = \frac{s_{xy}}{s_x s_y}$$

S_xy es la covarianza entre x e y.

S_x y S_y son la desviación estándar de x e y respectivamente.

r_xy es el coeficiente de correlación.

Este coeficiente se denomina **correlación lineal o de Pearson**, y es una cantidad adimensional. Por lo tanto, si cambiamos la unidad de x e y, el valor del coeficiente seguirá siendo el mismo.

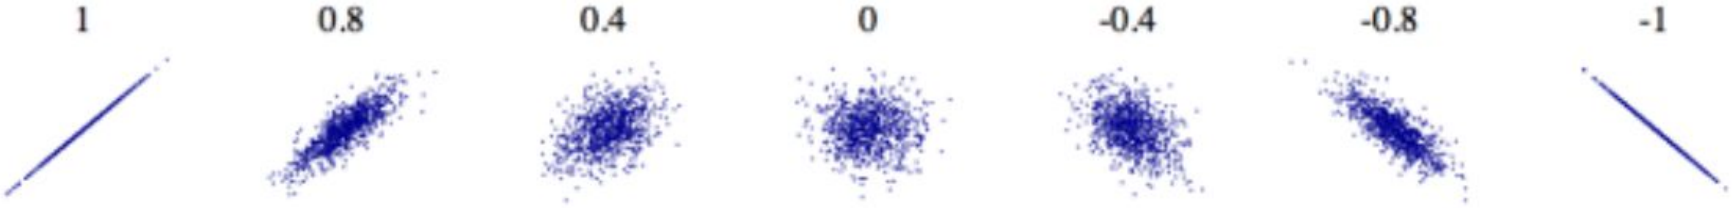
Correlación entre variables

- Correlación no implica causalidad.
- La correlación de Pearson es muy útil para encontrar correlaciones lineales.
- Si la relación entre las variables NO es lineal, existen otras correlaciones que pueden ser útiles: Spearman y Kendall.



Valor del coeficiente de correlación lineal

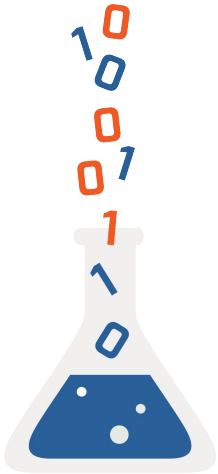
- **Negativo** significa que son inversamente proporcionales entre sí con el valor del factor de coeficiente de correlación.
- **Positivo** significa que son directamente proporcionales entre sí, la media varía en la misma dirección con el factor del valor del coeficiente de correlación.
- **Si el coeficiente de correlación es 0**, significa que no existe una relación lineal entre las variables, sin embargo, podría existir otra relación funcional.



Valor del coeficiente de correlación lineal

- Si no hay ninguna relación entre dos variables, entonces el coeficiente de correlación será ciertamente 0; sin embargo, si es 0, solo podemos decir que no existe una relación lineal, pero podría existir otra relación funcional:





Lab Time!

¡Muchas gracias!

¡Sigamos trabajando!