Machine Learning

Módulo 2

EDUCACIÓN IT

Árbol de decisión

Árbol de decisión

Este algoritmo divide el conjunto de datos en subconjuntos en forma sucesiva hasta obtener nodos en que la totalidad de sus elementos pertenecen a un mismo valor de la clasificación. La división está basada en el criterio más significativo para diferenciar los elementos:

- **Disminuir la Entropía / Ganancia de Información**.(*)
- **Gain Ratio**: corrige la preferencia de ganancia de información por atributos con demasiados valores.
- **Coeficiente o Impureza de Gini**: Apunta a que que las muestras obtenidas en la subdivisión sean lo más “puras” posibles. Es decir, tengan instancias de una sola de las clases.

Los árboles generalizan muy bien a problemas multiclase y de regresión.

(*) Al finalizar el módulo, hablaremos sobre la relación entre Entropía e Información.

Árbol de decisión

La disminución de entropía y la impureza de Gini son conceptos muy parecidos:

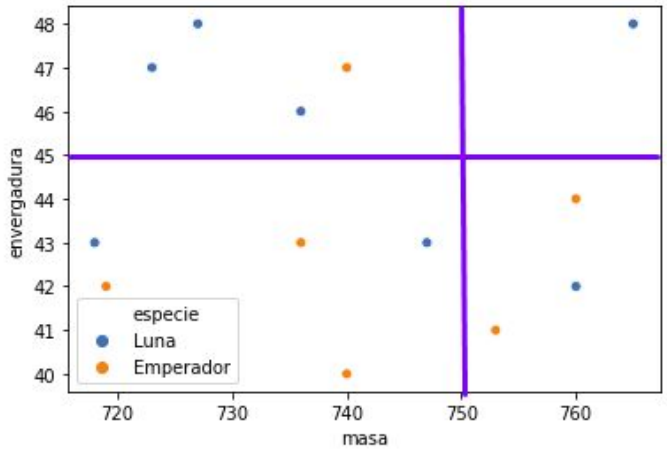
- Que cada nodo tenga la menor cantidad de clases distintas.
- El índice Gini busca disminuir la desigualdad entre los elementos de la clase.
- Cada nuevo nodo a su vez es separado en nuevos nodos secundarios, hasta llegar a la **condición de fin**, que puede ser **profundidad** o **cantidad mínima de elementos en cada nodo**.
- Hay un procedimiento estadístico que cuantifica la pureza de las muestras.



Árbol de decisión

Tomemos de ejemplo el caso de las mediciones de las dos especies de polillas. Queremos analizar esos datos para que, ante una nueva medición, se pueda predecir de qué especie se trata.

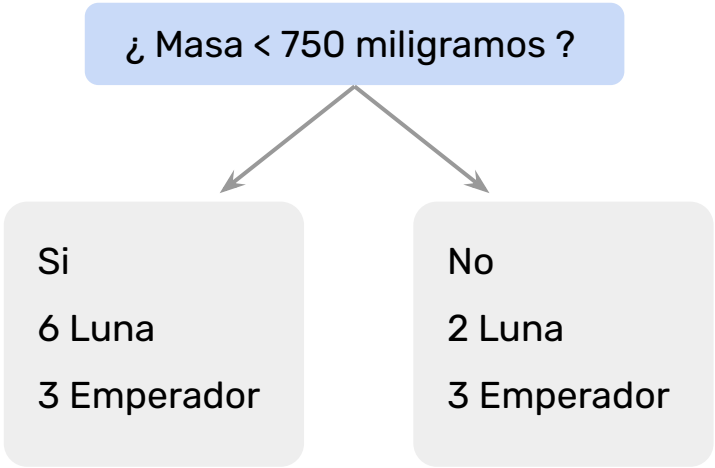
Como se puede ver, no es posible trazar dos líneas rectas que dividan perfectamente las clases, entonces el algoritmo buscará minimizar ese error.



masa	envergadura	especie
747	43	Luna
723	47	Luna
760	42	Luna
718	43	Luna
736	43	Emperador
727	48	Luna
719	42	Emperador
765	48	Luna
753	41	Emperador
740	40	Emperador
740	47	Luna
736	46	Luna
760	44	Emperador
740	47	Emperador

Árbol de decisión

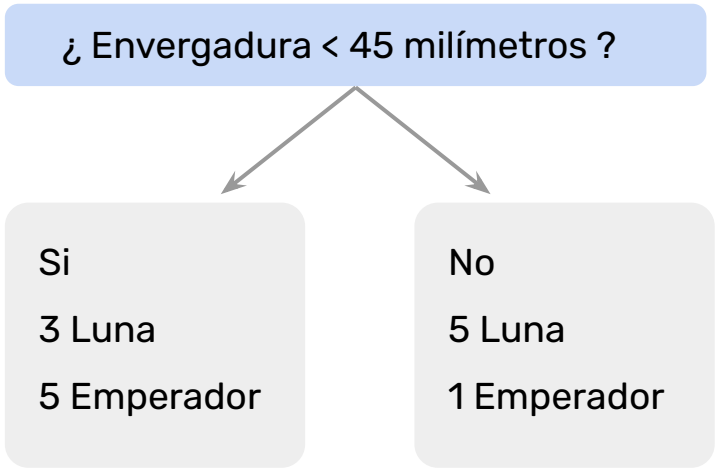
Se comienza construyendo una pregunta por cada columna y evaluando cuál deja mejor separadas las instancias:



masa	envergadura	especie
747	43	Luna
723	47	Luna
760	42	Luna
718	43	Luna
736	43	Emperador
727	48	Luna
719	42	Emperador
765	48	Luna
753	41	Emperador
740	40	Emperador
740	47	Luna
736	46	Luna
760	44	Emperador
740	47	Emperador

Árbol de decisión

Se comienza construyendo una pregunta por cada columna y evaluando cuál deja mejor separadas las instancias:



masa	envergadura	especie
747	43	Luna
723	47	Luna
760	42	Luna
718	43	Luna
736	43	Emperador
727	48	Luna
719	42	Emperador
765	48	Luna
753	41	Emperador
740	40	Emperador
740	47	Luna
736	46	Luna
760	44	Emperador
740	47	Emperador

Árbol de decisión

¿Cuál de las dos preguntas separó mejor las clases?

1. En primer lugar, se calcula la impureza de Gini de la muestra:

   $Gini_{inicial} = 1 - (proporción\ de\ Luna)^2 - (proporción\ de\ Emperador)^2$

   Son 14 instancias, 8 Luna y 6 Emperador:

   $Gini_{inicial} = 1 - (8/14)^2 - (6/14)^2 = 0.4898$

   ***Si la muestra tiene solamente miembros de una clase, entonces**

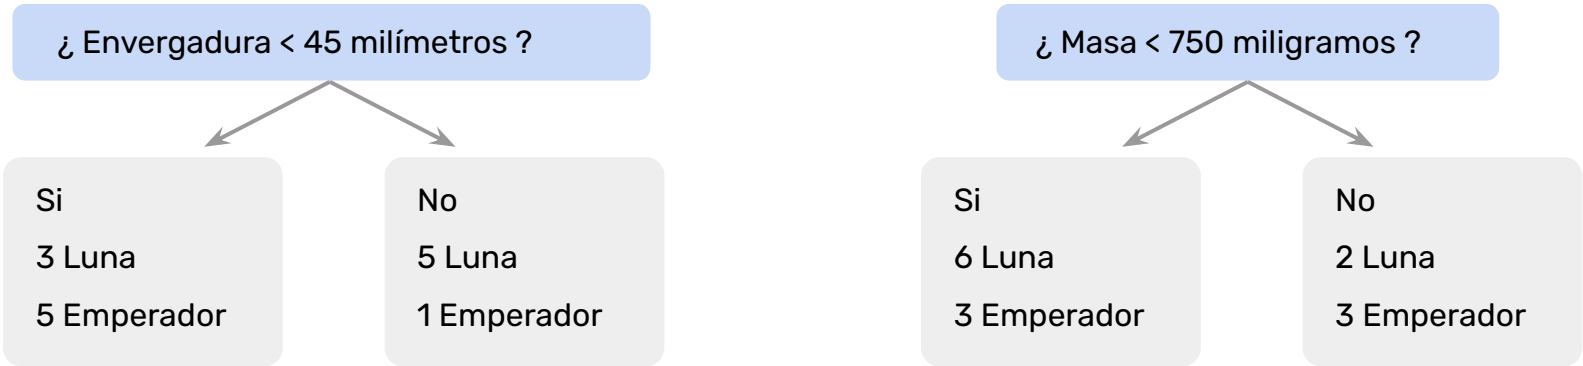
   $Gini = 1 - (proporción\ única\ clase)^2 = 0$

   ***y si tiene mitad y mitad:**

   $Gini = 1 - (1/2)^2 - (1/2)^2 = 0.5$

Árbol de decisión

2. Se calcula la Impureza Gini luego de hacer cada pregunta. Para eso se hace un promedio ponderado de las impurezas resultantes en cada hoja, por pregunta.



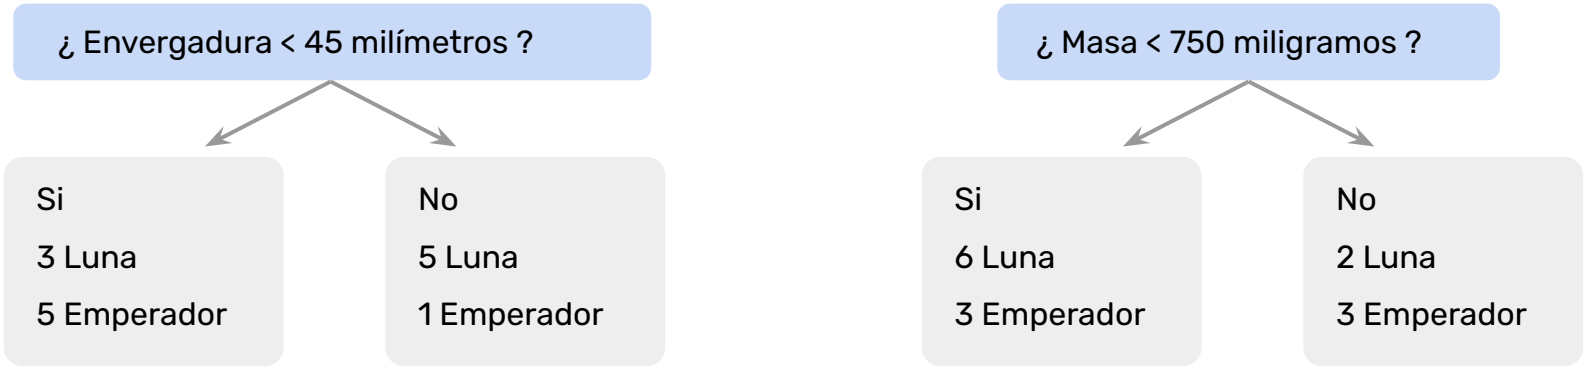
Gini para esta **hoja:**
$= 1 - (3/8)^2 - (5/8)^2$
$= 0.4688$

Gini para esta **hoja:**
$= 1 - (5/6)^2 - (1/6)^2$
$= 0.2778$

Gini para esta **hoja:**
$= 1 - (6/9)^2 - (3/9)^2$
$= 0.4444$

Gini para esta **hoja:**
$= 1 - (2/5)^2 - (3/5)^2$
$= 0.48$

Árbol de decisión



Gini para esta **hoja:**
$= 1 - (3/8)^2 - (5/8)^2$
$= 0.4688$

Gini para esta **hoja:**
$= 1 - (5/6)^2 - (1/6)^2$
$= 0.2778$

Gini para esta **hoja:**
$= 1 - (6/9)^2 - (3/9)^2$
$= 0.4444$

Gini para esta **hoja:**
$= 1 - (2/5)^2 - (3/5)^2$
$= 0.48$

Gini de Envergadura:
$= (8/14) * 0.4688 + (6/14) * 0.2778 =$ **0,3869**

Gini de Masa:
$= (9/14) * 0.4444 + (5/14) * 0.48 =$ **0,4571**

Árbol de decisión

3. Se elige el atributo con índice de impureza mas pequeño:

Gini Inicial = 0,4898

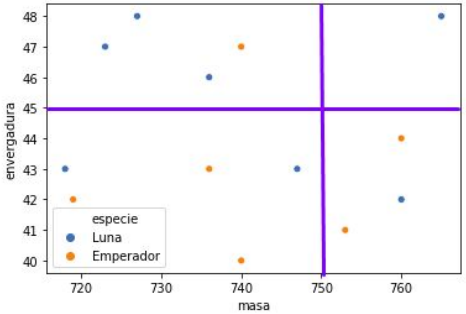
Gini de Envergadura = 0,3869

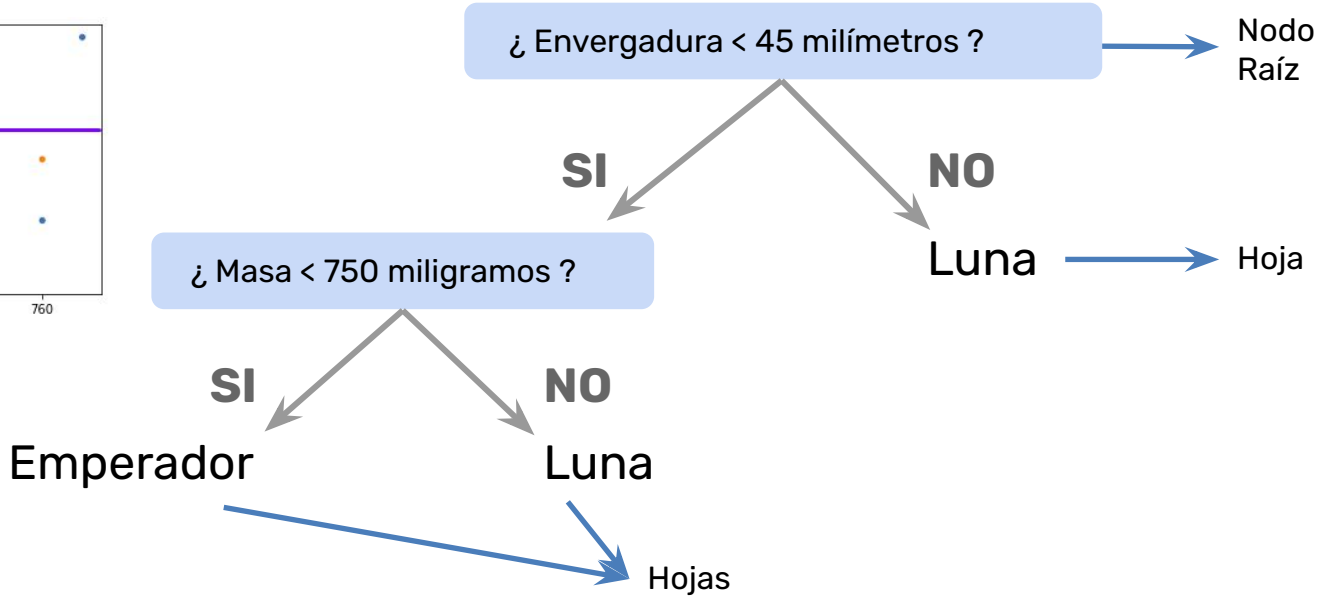
Gini de Masa = 0,4571

3. Si consideramos que las instancias ya están clasificadas suficientemente bien, se finaliza.
   Si no, seguimos construyendo el árbol de forma iterativa, tomando como muestra inicial la muestra de cada hoja y realizando los pasos 1 - 4.

Árbol de decisión

Finalmente, el árbol de decisión tendría la siguiente forma, con profundidad 2:





Árbol de decisión

Ventajas

- Simple de entender, interpretar y visualizar. Esto es una gran ventaja, también, al momento de comunicar nuestro trabajo.
- Entrenamiento rápido.
- Modelo base para modelos más complejos (Random Forest, XGBoost, etc.).
- ¡Muchas implementaciones y variantes!

Desventajas

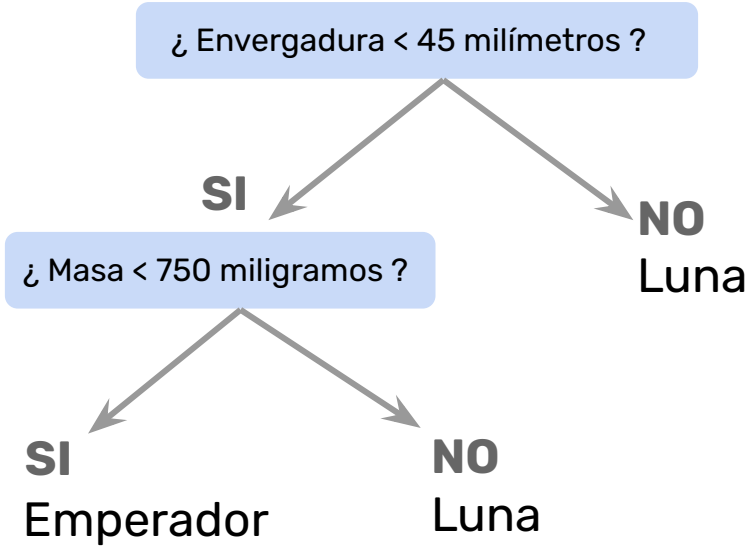
- Poder de generalización relativamente bajo en muchas circunstancias.
- Desempeño inferior a modelos más modernos.
- ¡Muchas implementaciones y variantes!

Enlace recomendado:
https://www.youtube.com/watch?v=z-EtmaFJieY

Parámetros e hiperparámetros

En los distintos modelos vamos a tener valores de ajuste sobre el algoritmo, algunos de los cuales podremos **modificarlos manualmente** y llamamos **hiperparámetro**, en el caso de este árbol de decisión, será su profundidad, que es 2 en este caso, la cantidad de elementos en que se puede dividir un nodo o el criterio de subdivisión (Gini o Entropía).

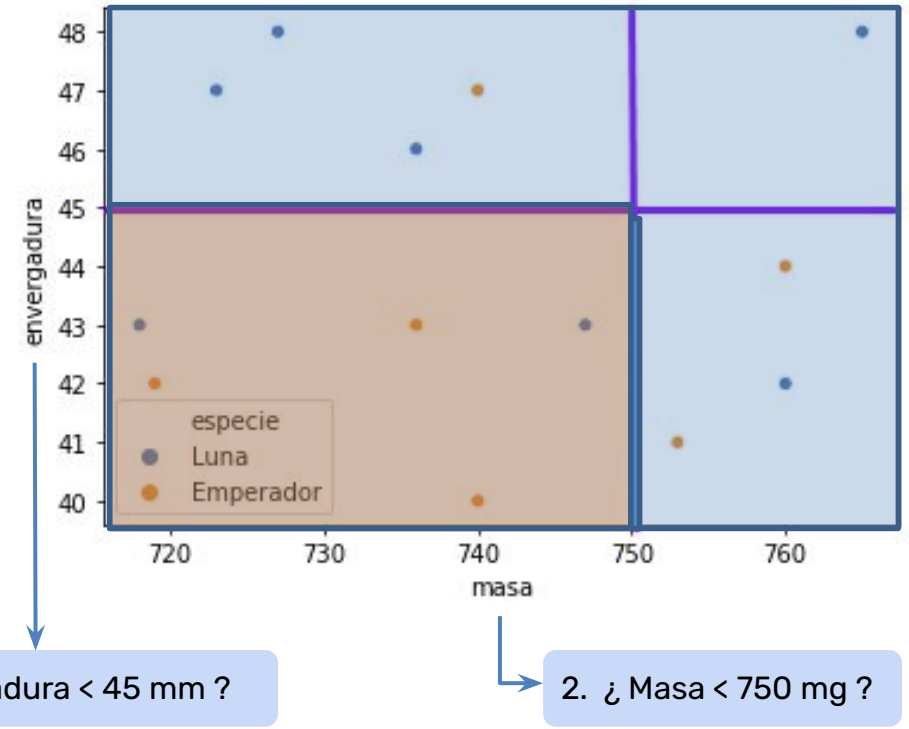
Por otra parte, existen valores de ajuste que son resultado del proceso interno del algoritmo, como por ejemplo los valores 45 y 750 del caso, esos **no se ajustan manualmente** y se denominan **parámetros**.



Fronteras de decisión

En los distintos modelos, podemos tener visualmente la distribución de los datos y también el resultado del proceso de aplicación algoritmo.

Tomando el caso del ejemplo, podemos observar las líneas de división de ambas especies, aplicando las dos preguntas tenemos los cuadrantes, uno de los cuales pertenecen a Emperador y los otros a Luna.

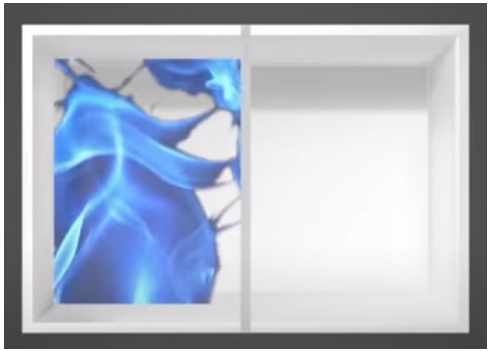


La entropía y la información

Trabajaremos con datos y una afirmación muy común va a ser **asociar a la Entropía con la pérdida de Información**, pero esto, ¿por qué es así? Sabemos qué es la Información, pero... ¿qué es la Entropía realmente?

La Entropía es la Segunda Ley de la Termodinámica, se encuentra en todos los procesos de la Naturaleza y no se requiere saber de Física ni fórmulas complejas para comprenderla, está basada en el sentido común:

> Imaginemos un gas dentro de una caja con un separador en el medio. Si se quita el separador, el gas se expande y ocupa toda la caja, pero ¿por qué esto es así? Y además, ¿por qué este fenómeno no es reversible?



Ese hecho se explica simplemente con la **Combinatoria, la Probabilidad y la Estadística.**

La entropía y la información

Recurramos a otro ejemplo:

> Si se tiran dos dados y hubiera que apostar a la suma de ambos, ¿a qué número apostarías?

Empezamos por la combinatoria y verificamos que la suma 7 es la de mayor número de ocurrencias posibles dentro de 36 combinaciones.

La suma 7 es el **estado inespecífico** con más configuraciones posibles, es decir, con más **estados específicos**.

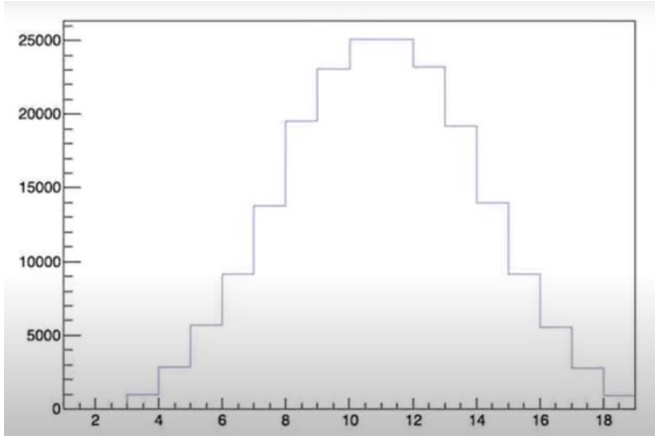
Y si en lugar de 2 dados, usamos 3 o usamos 100 ¿como se transformaría esa distribución de probabilidad?

Suma	Combinaciones
2	1
3	2
4	3
5	4
6	5
7	**6**
8	5
9	4
10	3
11	2
12	1

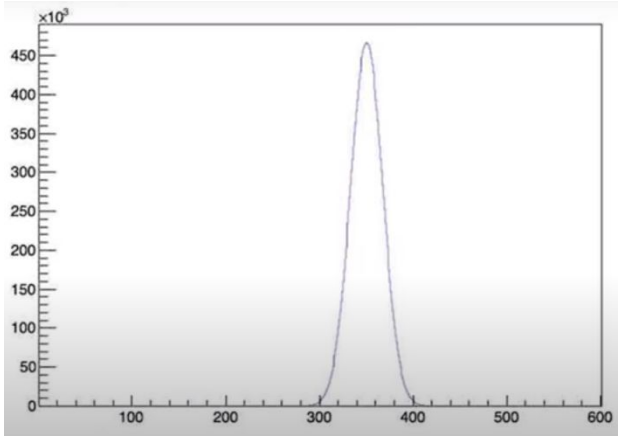


La entropía y la información

Conforme el número de elementos aumenta, la distribución de la probabilidad se hace más marcada hacia su centro.

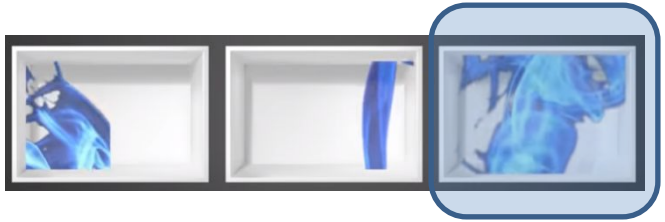






La entropía y la información

Entonces, si volvemos al ejemplo del gas, y tenemos en cuenta su cantidad de moléculas, ocupa toda la caja simplemente porque es su estado más probable.



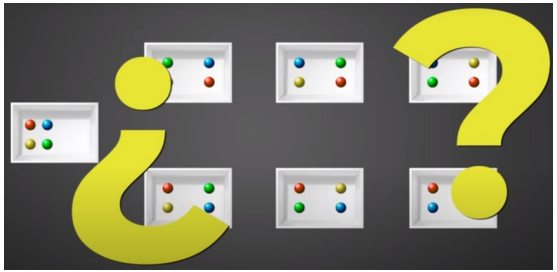
La Entropía mide la probabilidad de encontrar un estado debido a su multiplicidad. Un estado con alta Entropía es un estado muy probable, porque se puede alcanzar de muchas formas posibles equivalentes. El Universo tiende a aumentar la Entropía.

La entropía y la información

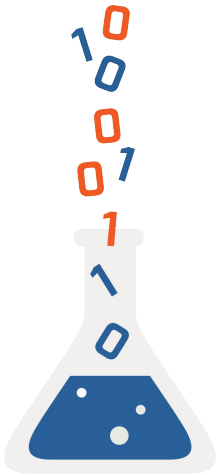
Entonces, **¿cuál es la relación con la Información?**

Si vemos a ese gas como sólo 4 moléculas de 4 colores diferentes, y sabemos que su estado más probable serán repartidas en los 2 lados de la caja, debido a tendrá la mayor cantidad (6) de estados posibles para acomodarse.

- ¿Exactamente dónde quedará cada una?
- Si todas están en un solo lado sabemos exactamente donde están, así que tenemos toda la información.
- Pero si no es así, nos falta información para saber de qué lado se quedará cada molécula.
- **El estado de máxima Entropía, que es precisamente aquél más probable, ¡implica la mayor pérdida de Información!**



Entropía:
"Un sistema aislado evoluciona siempre a un estado donde aumenta su **información perdida.**"



Lab Time!

¡Muchas gracias!

¡Sigamos trabajando!