Machine Learning

Módulo 3

EDUCACIÓN IT

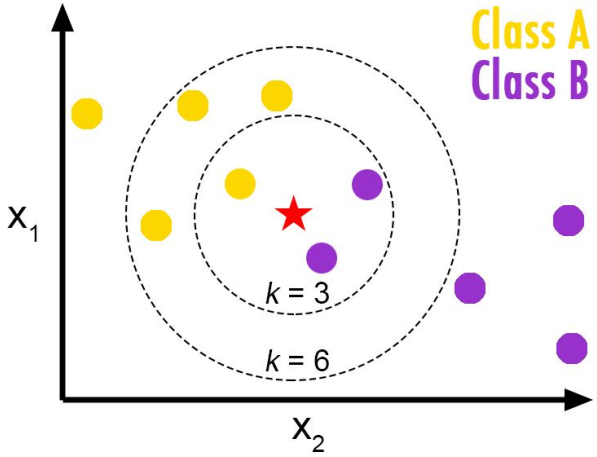
K-Vecinos más cercanos

K-Vecinos más cercanos (KNN)

Dada una nueva instancia de la cual no conocemos la etiqueta objetivo, vamos a asumir que su etiqueta será igual a la de las instancias “vecinas” en el conjunto de datos que tenemos.

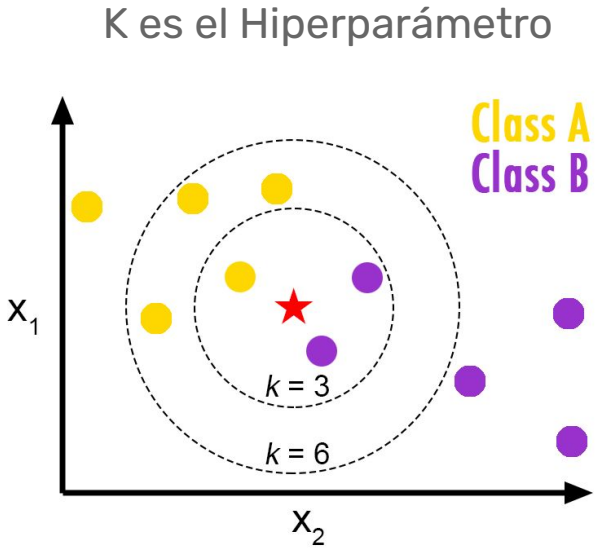
Por ejemplo, si tenemos los features X1 y X2, y además un tercer feature que es la clase, que puede ser A o B.

Dada una instancia nueva de la que no se conoce su clase, se recurre a sus vecinos más cercanos para clasificarla y K es la cantidad de vecinos que se evalúan para saber la clase de la nueva instancia.

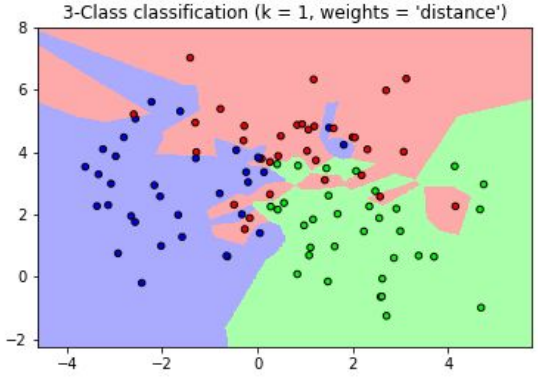


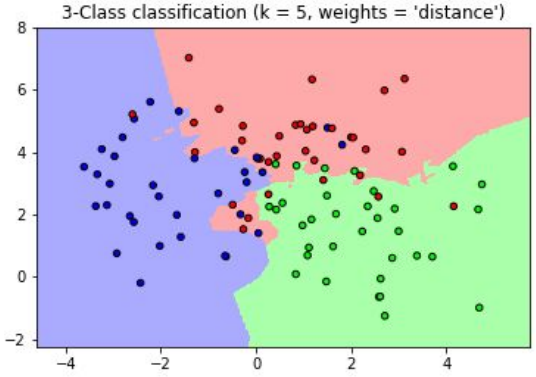
K-Vecinos más cercanos (KNN)

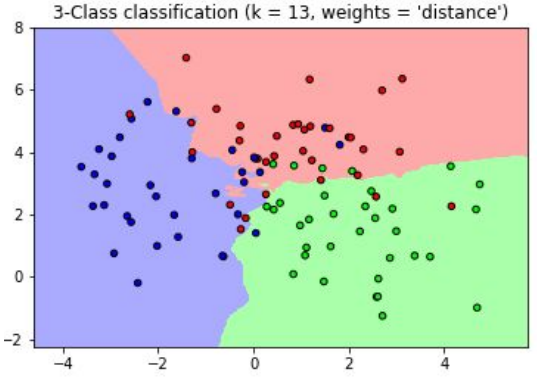
- Si tomamos K = 3, entonces vamos a clasificar la nueva instancia como de clase B, ya que habrá dos instancias de B y una de A.
- Si tomamos K = 6, entonces vamos a clasificar la nueva instancia como de clase A, ya que habrán cuatro instancias de A y dos de B.
- No hay una receta para elegir K de antemano, depende del problema. Normalmente la solución es probar varios valores y ver cual modelo se desempeña mejor.
- Puede ser muy importante reescalar los valores de los features, por ejemplo llevando a escala de z-score, antes de usar este modelo.



K-Vecinos más cercanos (KNN)







El valor que se elija para K va a ser determinante para el desempeño del modelo.

Enlace recomendado: *https://shapeofdata.wordpress.com/2013/05/07/k-nearest-neighbors/*

K-Vecinos más cercanos (KNN)

- Con **variables numéricas** se resuelve mediante **distancia Euclideana**, pero no es la única, también puede hacerse mediante la **distancia de Manhattan** o la de **Minkowski:**

Euclidean $\sqrt{\sum_{i=1}^{k}(x_i - y_i)^2}$

Manhattan $\sum_{i=1}^{k}|x_i - y_i|$

Minkowski $\left(\sum_{i=1}^{k}(|x_i - y_i|)^q\right)^{1/q}$

- Con **variables categóricas** se resuelve mediante distancia de Hamming, diferencia entre los caracteres de las palabras:

$$D_H = \sum_{i=1}^{k}|x_i - y_i|$$

$$x = y \Rightarrow D = 0$$

$$x \neq y \Rightarrow D = 1$$

X	Y	Distance
Male	Male	0
Male	Female	1

Enlace recomendado: *https://shapeofdata.wordpress.com/2013/05/07/k-nearest-neighbors/*

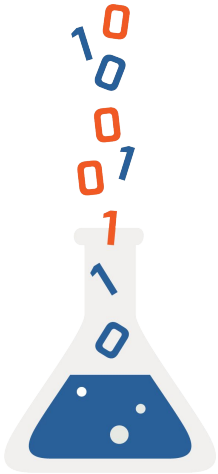
K-Vecinos más cercanos (KNN)

Ventajas

- Simple de entender, interpretar y visualizar. Esto es una gran ventaja, también, al momento de comunicar nuestro trabajo.
- Entrenamiento rápido. Esta etapa consiste simplemente en “recordar” los datos.

Desventajas

- Lento para clasificar.
- Ocupa mucho espacio en el disco (tiene que guardar todo el set de entrenamiento).



Lab Time!

¡Muchas gracias!

¡Sigamos trabajando!