Machine Learning

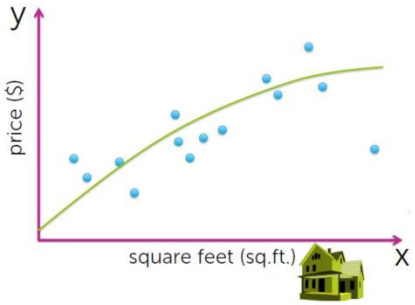
Módulo 3

EDUCACIÓN IT

Regresión

Regresión polinómica

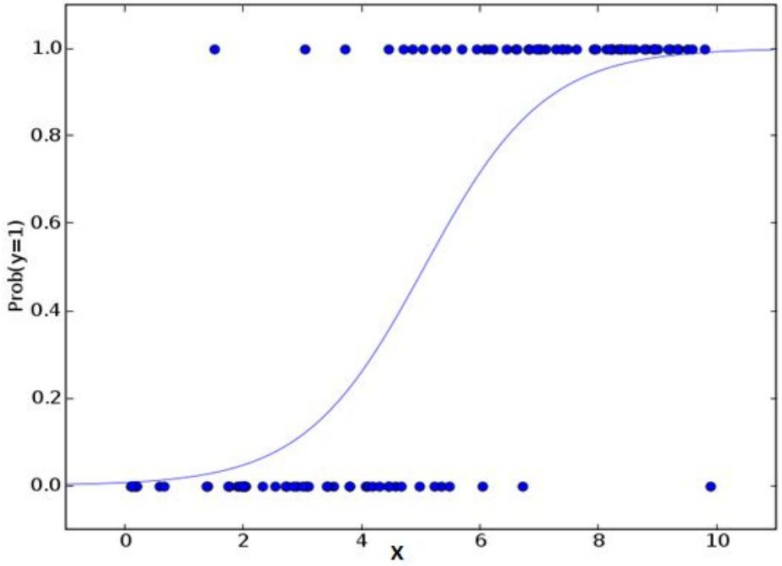
- Utiliza un polinomio de **grado n**, con n>= 2.
- Lo más habitual es utilizar hasta n=4. Más allá se corre el riesgo de caer en un sobre ajuste del modelo a los datos, hecho conocido como **overfitting** o **sobreadaptación.** Lo que consiste en un modelo que se ajusta excelente a los datos conocidos pero no tiene buen desempeño con los nuevos casos.
- La regresión polinómica selecciona la función con menor error cuadrático medio.
- Veamos ejemplo de los valores de una propiedad con una función cuadrática (grado 2)



Regresión logística

- Es un caso particular de la regresión lineal, y consiste en que el resultado será binario, es decir, **0 o 1**. Por eso su nombre.
- También se la denomina **Sigmoide,** la cual es de uso común en redes neuronales.

$$P(t) = \frac{1}{1 + e^{-t}}$$



Regresión con K-Vecinos (KNN)

Consiste en predecir la variable buscada en función al promedio ponderado de las instancias vecinas más cercanas.

En el ejemplo de los valores de las propiedades:

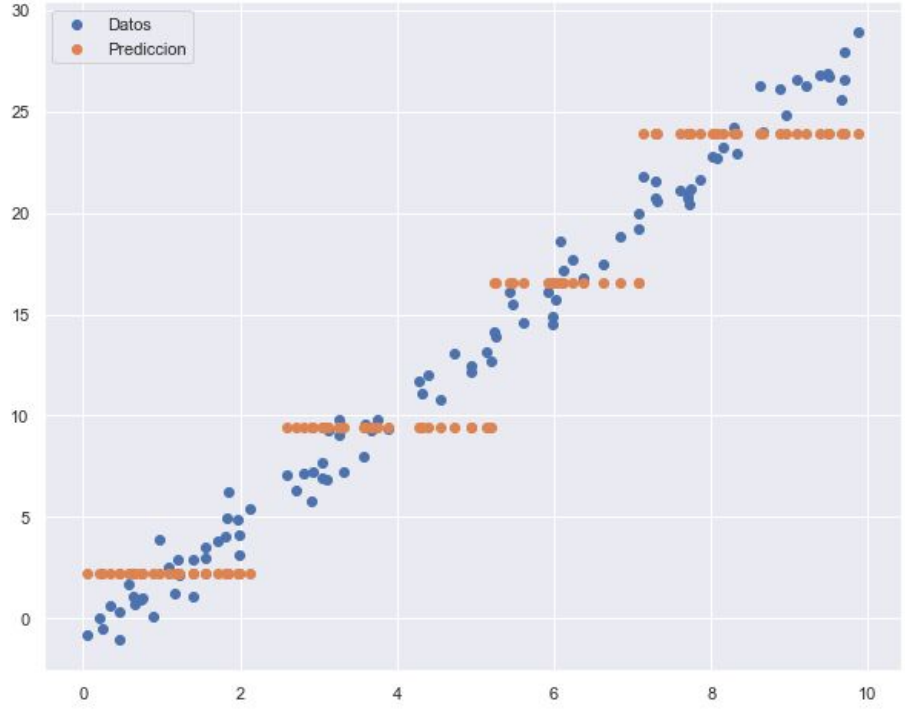
- La nueva instancia es Loan=142.000, queriendo predecir HPI.
- Si K=1, entonces es directamente el valor de la instancia más cercana, es decir 264.
- Si K=3, será el promedio de los HPI de las 3 instancias más cercanas, es decir 180.7
- Notar que las distancias podrían hacerse en base a Loan y Age juntas.

Age	Loan	House Price Index	Distance	
25	$40,000	135	102000	
35	$60,000	256	82000	
45	$80,000	231	62000	
20	$20,000	267	122000	
35	$120,000	139	22000	2
52	$18,000	150	124000	
23	$95,000	127	47000	
40	$62,000	216	80000	
60	$100,000	139	42000	3
48	$220,000	250	78000	
33	$150,000	264	8000	1
48	**$142,000**	**?**		

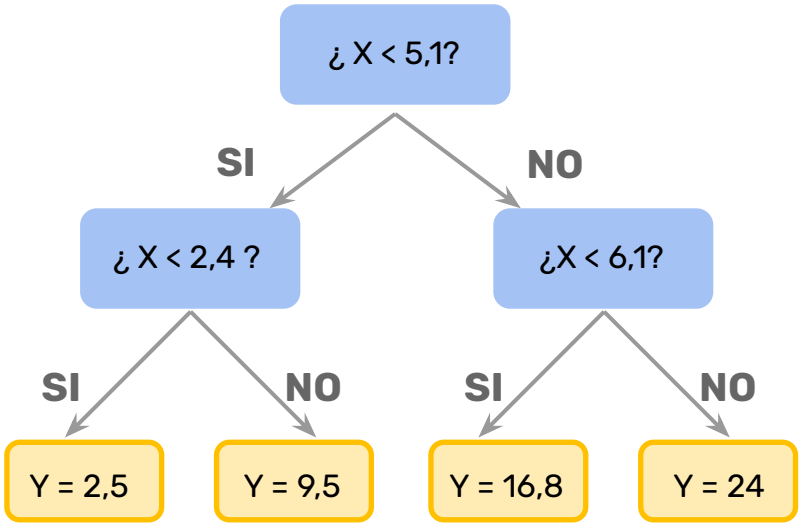
Enlace recomendado:
https://www.saedsayad.com/k_nearest_neighbors_reg.htm

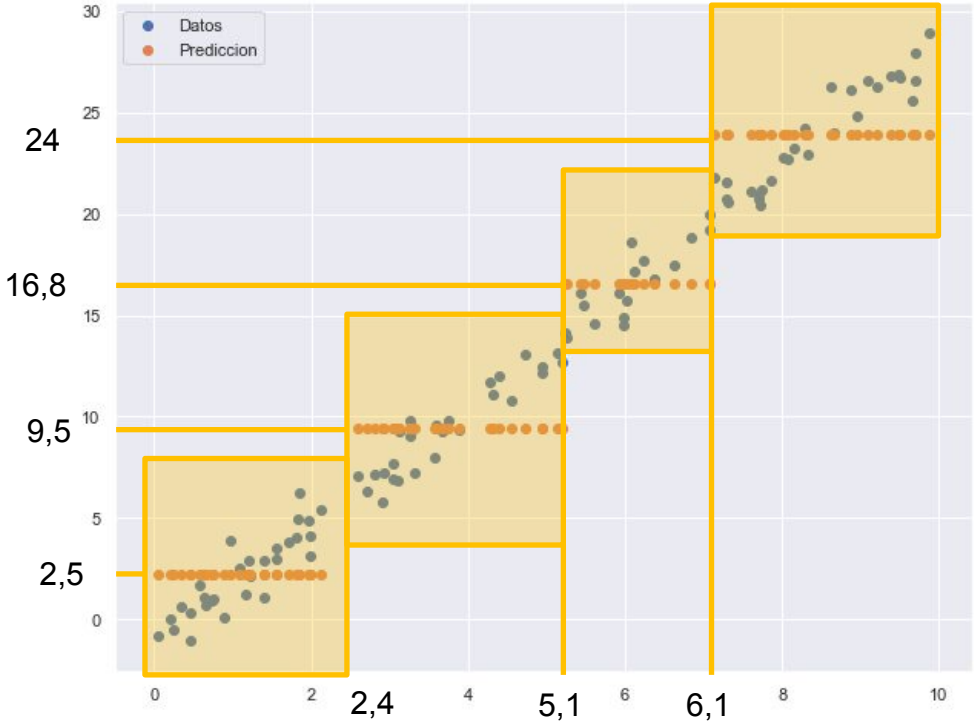
Regresión con árbol de decisión

- El resultado de cada nodo, será la variable destino, dada en función de la/s variable/s utilizadas para entrenar.
- En cada nodo, se usa reducción de desvío estándar de Y.
- Una hoja devuelve el promedio de Y sobre las instancias de la hoja.
- Como hiperparámetro se usó la profundidad 2.



Regresión con árbol de decisión





Enlace recomendado:
https://www.youtube.com/watch?v=zvU0pbgtW3c

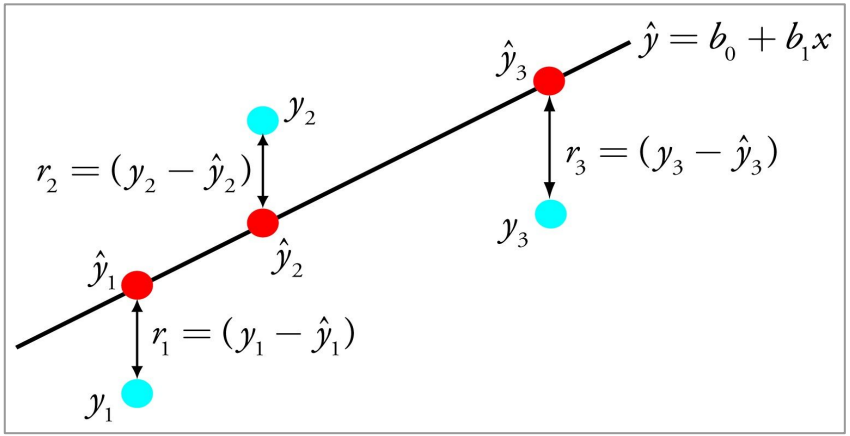
Error en problemas de regresión

MAE (Error absoluto medio):

- Se suman las distancias entre el valor en y real, y el predicho. Aunque esos errores tienen distinto signo. Si sumamos sin considerar eso, podría suceder que se cancelen.
- Sumando los valores absolutos, queda resuelto ese problema:

$$\mathrm{MAE}(y, \hat{y}) = \frac{1}{n_{\text{samples}}} \sum_{i=0}^{n_{\text{samples}}-1} |y_i - \hat{y}_i|$$

- Sin embargo ahora, a mayor cantidad de muestras el error se hace mayor.

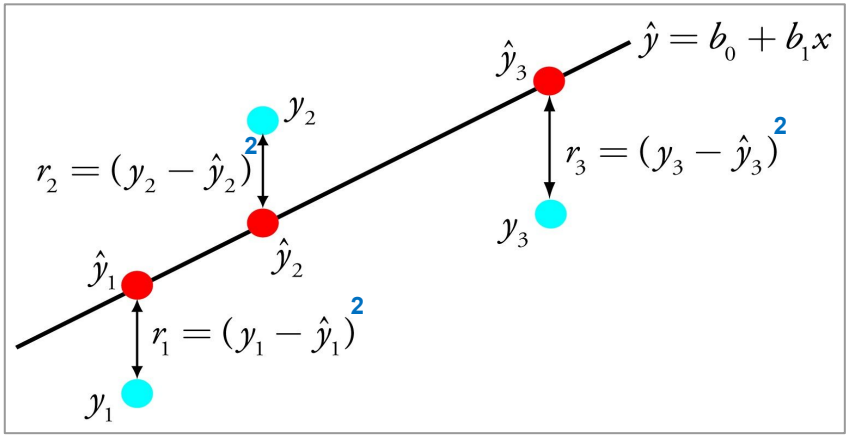


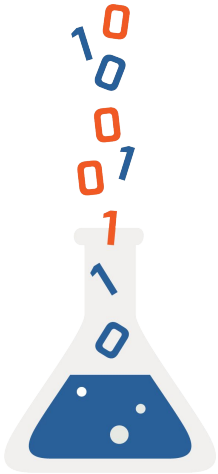
Error en problemas de regresión

MSE (Error cuadrático medio):

- Si se calcula el promedio de la **suma de errores** entre la predicción de un punto y su valor real, pero este error **elevado al cuadrado**.
- Lo que se obtiene es error cuadrático medio, y la línea que lo minimice será la propuesta por la regresión.

$$\mathrm{MSE}(y, \hat{y}) = \frac{1}{n_{\text{samples}}} \sum_{i=0}^{n_{\text{samples}}-1} (y_i - \hat{y}_i)^2$$





Lab Time!

¡Muchas gracias!

¡Sigamos trabajando!