Machine Learning

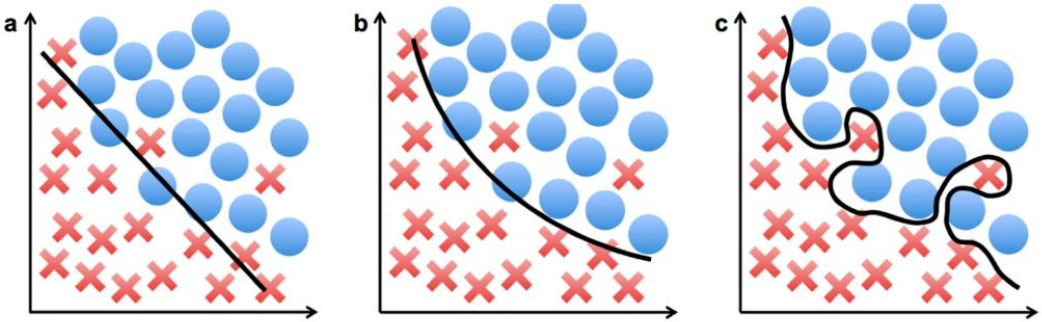
Módulo 3

EDUCACIÓN IT

Evaluación de modelos

Evaluación de modelos

La intención es evaluar si el modelo está aprendiendo o no de los datos. Una manera de hacerlo es **verificar su desempeño frente a nuevas instancias**. Pero, ¿por qué necesitamos nuevas instancias y no usamos, simplemente, las instancias que usamos para entrenar?

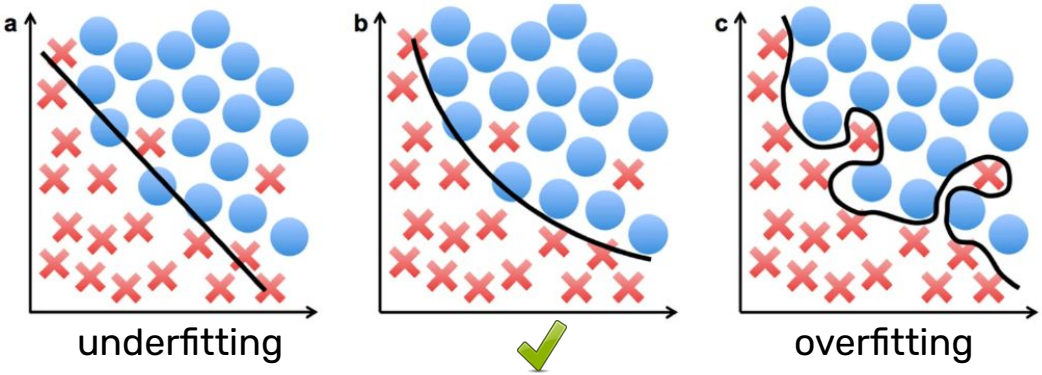


- ***¿Qué está pasando en cada una de las 3 situaciones?***
- ***¿Cuál de las 3 líneas separa mejor las cruces de los círculos?***

Evaluación de modelos

Es claro que la opción “c” separa mejor debido a que tiene una adaptación mayor a los datos, esto se denomina **overfitting** o **sobreajuste.**

Por su parte, la opción “a” es la que peor reproduce la frontera entre ambos grupos, por el contrario presenta baja adaptación a los datos o **underfitting**.

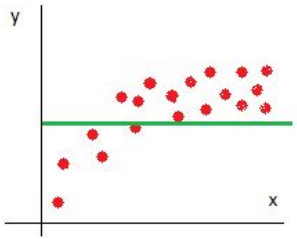


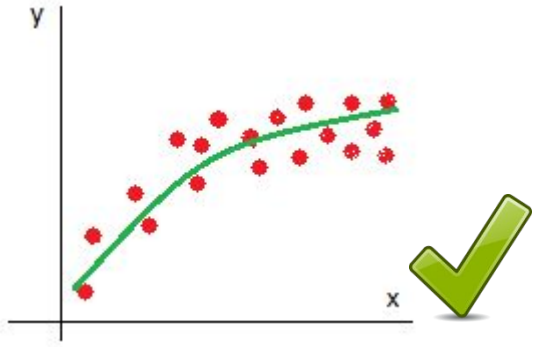
Enlace recomendado:
https://www.nature.com/articles/s41598-017-10324-y

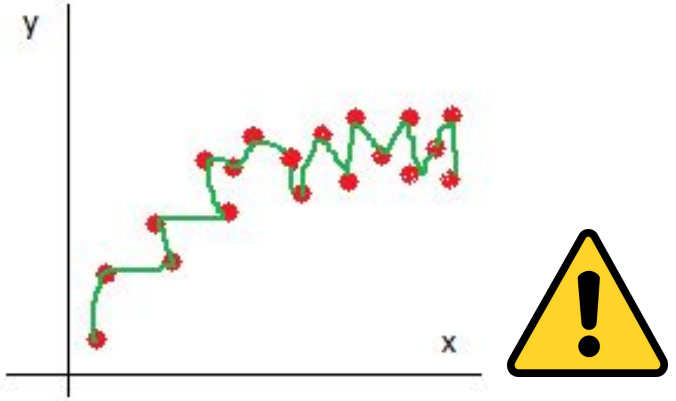
Evaluación de modelos

Un ajuste intermedio suele ser el apropiado, ya que los datos que tenemos son de entrenamiento y sabemos que tendremos que analizar datos que no se conocen. Entonces un ajuste muy alto puede ser contraproducente.

Muchos modelos son muy flexibles y, de esas dos situaciones, en general tendremos que preocuparnos más por el overfitting o sobreajuste.







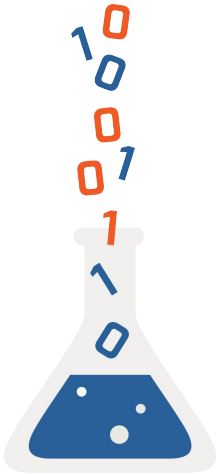
Evaluación de modelos

En el flujo de trabajo se emula una situación donde el modelo es entrenado con ciertos datos y luego es evaluado con datos nuevos.

- Se separa una porción de los datos:
  En ocasiones esta separación no es al azar, sino que tiene un cierto criterio, esto depende del problema.
- Se evalúa el desempeño del modelo sobre los datos de entrenamiento.
- Luego, se evalúa sobre los datos que restan, que van a oficiar de esos datos que el modelo “nunca vio” y son nuevos.
- En todos los entornos de desarrollo de Machine Learning existe una función que hace la tarea de separación de los datos. En Scikit-Learn, la función se llama **train_test_split()**.

Evaluación de modelos

- En **Árboles de Decisión**, el overfitting se controla principalmente con el hiperparámetro de profundidad.
  - Evitando construir el árbol más allá de cierta profundidad.
  - Construir el árbol entero, y luego “podar” las ramas cuando ello mejore la performance sobre los datos separados.
- En **K-Vecinos** el valor de K es determinante:
  - Si K=1 es lo mismo que simplemente tomar a la instancia más cercana como idéntica.
  - Si K es cercano al número de instancias es como tomar al promedio de la mayoría como la predicción o clasificación.
- En **Regresiones polinómicas**, si el grado es demasiado alto, se forma una curva que se ajusta demasiado a los datos de entrenamiento.



Lab Time!

¡Muchas gracias!

¡Sigamos trabajando!