Machine Learning

Módulo 3

EDUCACIÓN IT

Validaciones

Validación cruzada

¿Cómo podemos evaluar si el modelo está aprendiendo o no de nuestros datos?

Una forma práctica de evaluar si nuestro modelo aprendió o no de nuestro datos es observar su desempeño frente a nuevas instancias.

En nuestro flujo de trabajo, tendremos que emular una situación donde el modelo es entrenado con ciertos datos y luego es evaluado con datos nuevos.

Train/Test Split

1. Separo los datos en dos conjuntos, Train y Test.
2. Entreno con los datos de Train
3. Evalúo el desempeño del modelo los datos de Test.

Validación cruzada

Evaluar el desempeño del sobreajuste de Test tiene varios usos:

1. Obtenemos una evaluación realista del desempeño de nuestros modelos.
2. Nos permite seleccionar el modelo que mejor desempeña sobre nuestros datos.

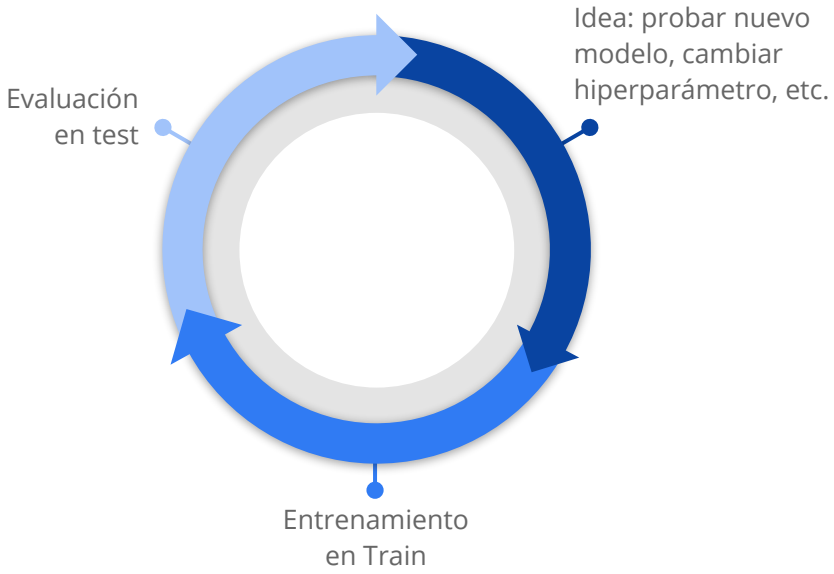
Pero Machine Learning involucra un proceso altamente iterativo. En general, entrenamos muchos modelos, ya sea de distinto tipo o variando hiperparámetros.

Validación cruzada

A medida que entrenamos nuevos modelos, puede ocurrir que un modelo tenga una buena performance en el conjunto de Test por **azar.**

Podemos creer que estamos seleccionando el mejor modelo disponible cuando en realidad estamos seleccionando un modelo mediocre.

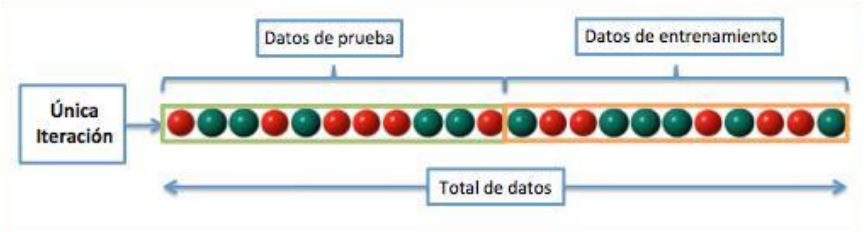
¿Se puede hacer mejor?



Validación cruzada

Separamos los datos con los que contamos en datos de entrenamiento y datos de prueba.

Se entrena con los datos de entrenamiento y se mide la performance con los datos de prueba.

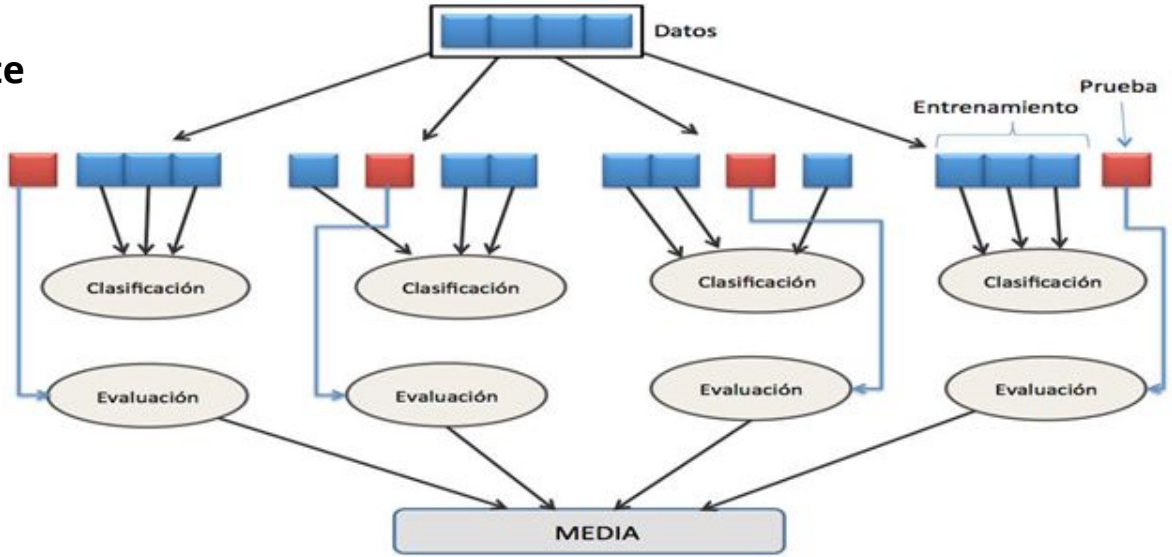


El objetivo de la validación cruzada es obtener una evaluación de performance de nuestro modelo que sea independiente de la partición en entrenamiento y prueba de los datos.

Fuente: https://es.wikipedia.org/wiki/Validaci%C3%B3n_cruzada

Validación cruzada

Haciendo **muchas particiones** esperamos que la medida de performance sea **independiente** de la partición de los datos.

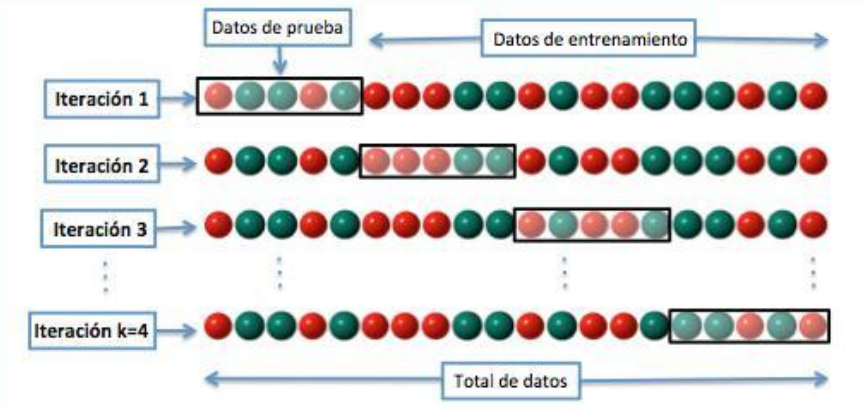


Fuente: https://es.wikipedia.org/wiki/Validaci%C3%B3n_cruzada

Validación cruzada

Existen diferentes técnicas de validación cruzada:

K-fold Cross Validation:



Es importante notar, que cada dato aparece una sola vez en los datos de prueba y k-1 en los datos de entrenamiento.

Fuente: https://es.wikipedia.org/wiki/Validaci%C3%B3n_cruzada

Validación cruzada

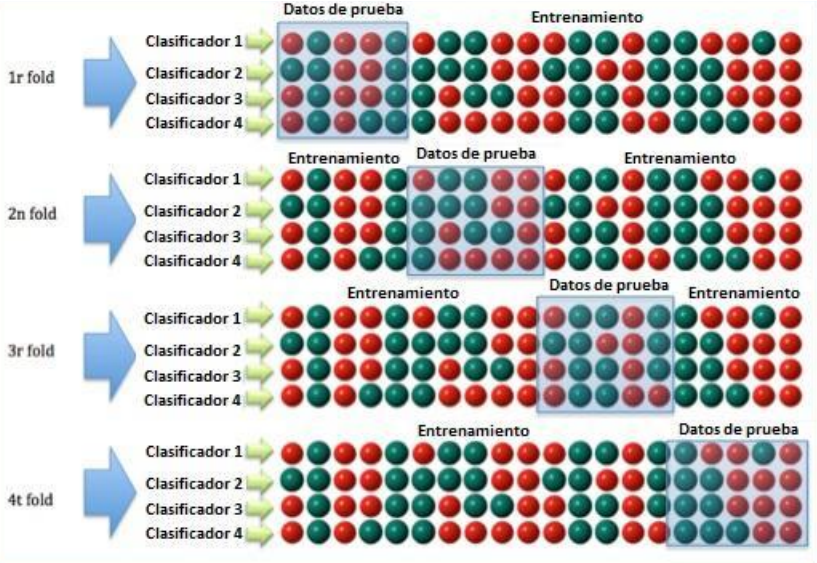
K-fold Cross Validation:

1. Desordenar los datos.
2. Separar en K folds (muestras) del mismo tamaño.
3. Para cada fold que separamos:
    a. Elegir la fold como Test set, y las K-1 folds restantes como Train set.
    b. Entrenar y evaluar el modelo.
    c. Guardar el resultado de la evaluación y descartar el modelo.
4. Obtener una medida de performance del modelo como el promedio de las K evaluaciones obtenidas en (3). También es una buena práctica incluir una medida de la varianza de las métricas obtenidas porque nos da una noción de cuánto puede afectar haber elegido un grupo de datos de Test u otro.

Fuente: https://es.wikipedia.org/wiki/Validaci%C3%B3n_cruzada

Validación cruzada

Comparando muchos modelos con K-fold Cross Validation:



Performance 1 de cada modelo

Performance 2 de cada modelo

Performance 3 de cada modelo

Performance k=4 de cada modelo

Promedio y Varianza de cada Modelo

Fuente: https://es.wikipedia.org/wiki/Validaci%C3%B3n_cruzada

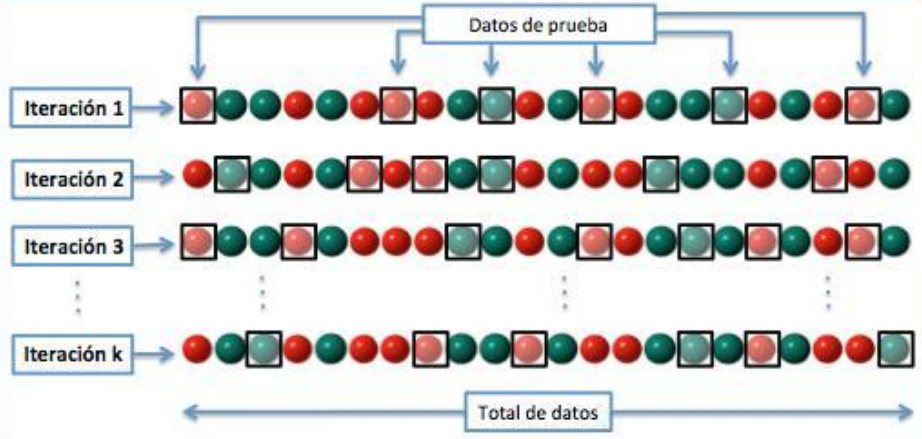
Validación cruzada

Conclusiones sobre K-fold Cross Validation

- La validación cruzada es un **procedimiento de remuestreo** que se utiliza para evaluar modelos de aprendizaje automático en una muestra de datos limitada.
- **El hiperparámetro más importante es k** que se refiere al número de grupos en que se dividirá una muestra de datos dada.
- Es un **método popular porque es fácil de entender** y porque generalmente resulta en una estimación **menos *sesgada* o menos optimista** de la habilidad del modelo que otros métodos, como una simple división de train / test.
- **¡No siempre hay que separar al azar!** En algunos casos (por ejemplo, predicción con series de tiempo), la validación cruzada toma otra forma.
- La validación cruzada está **íntimamente relacionada con la optimización de hiperparámetros**.

Validación cruzada

Validación Cruzada Aleatoria:



En este caso, cada dato puede aparecer más de una vez en el conjunto de prueba.

Fuente: https://es.wikipedia.org/wiki/Validaci%C3%B3n_cruzada

Validación cruzada

Validación Cruzada Aleatoria:

1. Se hace un train/test split para separar dos conjuntos: uno de desarrollo (dev, también llamado train) y uno de Held-Out (también llamado a veces test):

Desarrollo	**Held-Out**
- Experimentación con atributos, algoritmos e hiperparámetros.	- Estimación realista de performance

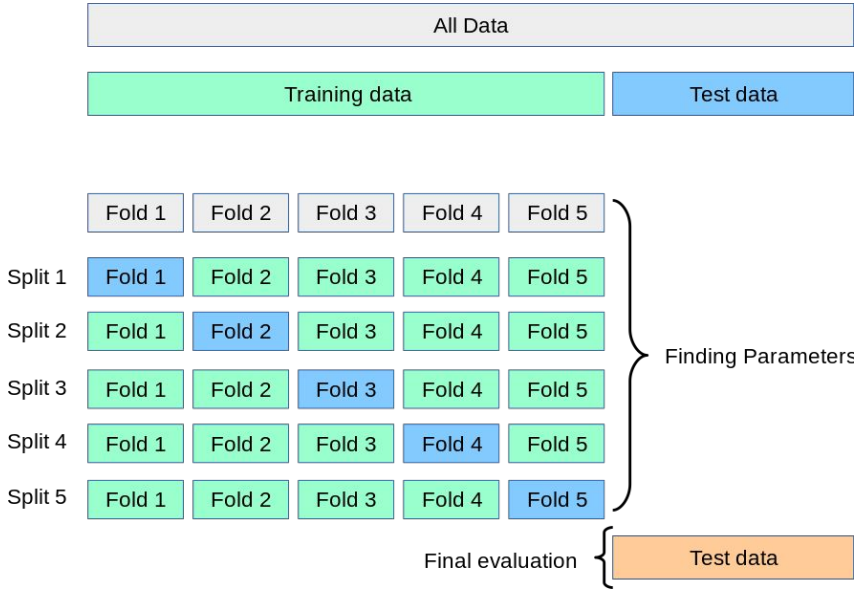
2. Dentro del conjunto de desarrollo, se hacen **todas las pruebas** que consideremos necesarias y evaluamos los modelos resultantes usando **validación cruzada**. Se elige el modelo a partir del desempeño en estos datos (y las otras condiciones que consideremos para el problema, como exhaustividad, ***Navaja de Ockham***, etc.).

Navaja de Ockham: *Ante igualdad de condiciones, la explicación más sencilla suele ser la más probable.*

Validación cruzada

Validación Cruzada Aleatoria:

3. Se evalúa el desempeño del modelo elegido en el conjunto de Held-Out. Es el desempeño que se reporta.



Fuente: https://scikit-learn.org/stable/modules/cross_validation.html

Validación cruzada

Es muy importante, tanto que viene en todos los entornos de desarrollo de Machine Learning:

En **Scikit-Learn:**

- Documentación en Scikit-Learn sobre Validación Cruzada.
- Funciones incorporadas en el módulo model_selection

Curvas de validación

En general, el desempeño de un modelo depende de **muchos hiperparámetros**. Pero a veces hay uno que es el más importante, que predomina sobre el resto.

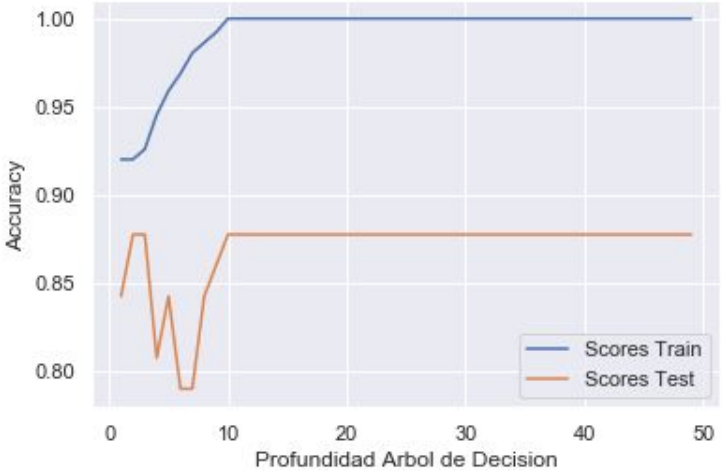
Para elegir el valor de ese hiperparámetro - y también caracterizar mejor el desempeño de nuestro modelo -, es útil obtener las curvas de validación.

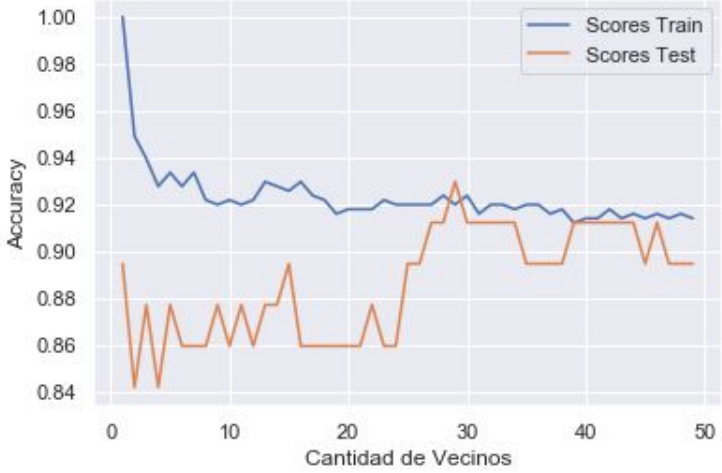
Una curva de validación nos muestra el desempeño del modelo, tanto en el conjunto de entrenamiento como de testeo, en función de un hiperparámetro.

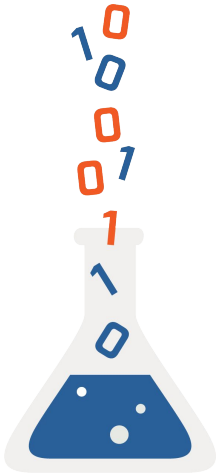
Como, en general, el hiperparámetro que variemos va a modificar la "complejidad" del modelo (profundidad en árboles, vecinos en KNN, etc.), también nos sirve para **diagnosticar overfitting y underfitting**.

Curvas de validación

Es importante evaluar los modelos desde el punto de vista del problema que queremos resolver, y no quedarse únicamente en una medida de desempeño estadística. La curva de validación nos muestra el desempeño en función de los hiperparámetros, tanto para los datos de entrenamiento como los de prueba.







Lab Time!

¡Muchas gracias!

¡Sigamos trabajando!