Machine Learning

Módulo 4

Sesgo y Varianza

Sesgo y Varianza

No es posible construir un modelo “perfecto” debido a que nunca podría estar libre de errores.

Comprender cómo son - y cómo influyen - las diferentes fuentes de errores nos ayudará a mejorar el proceso de ajuste de datos, lo que resultará en mejores modelos y, adicionalmente, también evitará el sobreajuste (overfitting) y falta de ajuste (underfitting).

El error de predicción para cualquier algoritmo de Machine Learning se puede dividir en tres partes:

- Error irreducible (ruido).
- Error de bias (sesgo).
- Error de varianza.



Sesgo y Varianza

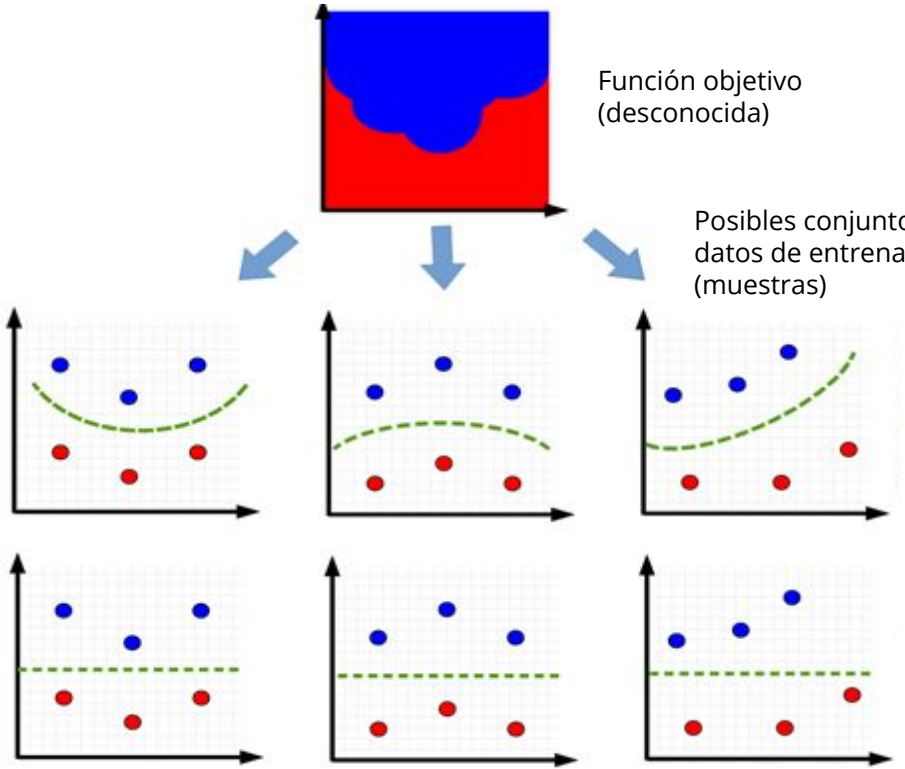
El error irreducible:

- No se puede reducir.
- Se lo conoce como *Ruido.*
- Proviene de factores como:
  - Variables desconocidas que influyen en el mapeo de las variables de entrada a la variable de salida.
  - Un conjunto de características incompletos.
  - Un problema mal enmarcado.

No importa cuán bien esté el modelo, los datos tendrán cierta cantidad de ruido o un error irreductible que no se puede eliminar.

En cambio, **los errores de sesgo y varianza se pueden reducir porque se derivan de la elección del algoritmo de entrenamiento y del modelo.**

Sesgo y Varianza



Línea de corte: **parábola.**
Bajo sesgo: mejores chances de acercarse al objetivo.
Alta varianza: los modelos construidos cambian mucho según la muestra.

Línea de corte: **recta horizontal.**
Alto sesgo: peores chances de acercarse al objetivo.
Baja varianza: los modelos construidos **cambian pocos** egún la muestra.

Sesgo y Varianza

El error de sesgo:

El sesgo es el error que introducimos al intentar explicar un problema del mundo real al que le correspondería un modelo complejo con un modelo bastante más simple.

En general, modelos más flexibles y más complejos, implican menos sesgo.

Bajo BIAS:

Sugiere menos suposiciones sobre la forma de la función objetivo:

- Árbol de Decisión
- K-Vecinos más cercanos
- Support Vector Machine

Alto BIAS:

Sugiere más suposiciones sobre la forma de la función objetivo:

- Regresión Lineal
- Análisis discriminante lineal
- Regresión Logística

Sesgo y Varianza

El error de varianza:

La varianza es la cantidad en la que cambiaría la predicción de haber entrenado el modelo con un conjunto de datos diferente. Por ejemplo, un modelo que se ajuste mucho a unos datos sufrirá una varianza considerable al cambiar dichos datos, y viceversa.

Baja Varianza

Sugiere pequeños cambios en la estimación de la función objetivo con el conjunto de datos de la capacitación:

- Regresión Lineal
- Análisis Discriminado Lineal
- Regresión Logística

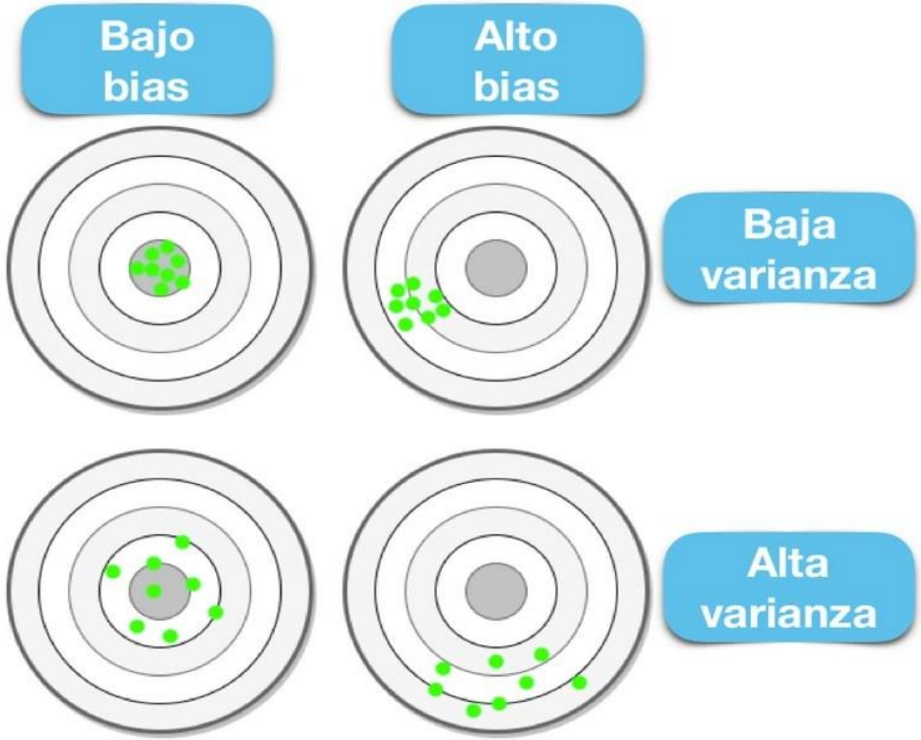
Alta Varianza:

Sugiere grandes cambios en la estimación de la función objetivo con el conjunto de datos de la capacitación:

- Árbol de Decisión
- K-Vecinos más cercanos
- Support Vector Machine

Sesgo y Varianza

Observar el efecto del sesgo y la varianza sobre la predicción de un modelo, donde los puntos sobre la diana son diferentes ejecuciones del mismo.



Sesgo y Varianza

Los algoritmos de **baja varianza** (alto bias) tienden a ser **menos complejos**, **con una estructura subyacente simple o rígida**.

Entrenan **modelos que son consistentes, pero inexactos en promedio**. Estos incluyen algoritmos paramétricos o lineales, como la regresión lineal y Naive Bayes.



Sesgo y Varianza

Los algoritmos de **bajo bias** (alta varianza) tienden a ser **más complejos, con una estructura subyacente flexible**.

Entrenan **modelos que son exactos en promedio pero inconsistentes**. Estos incluyen algoritmos no lineales o no paramétricos, como árboles de decisión y k-vecinos más cercanos.

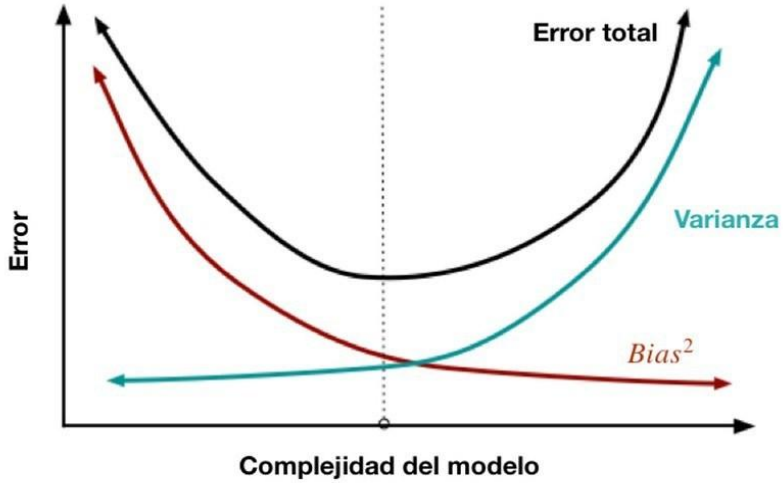


Sesgo y Varianza

Cuanto más flexible sea el modelo, la varianza aumentará, y el sesgo disminuirá. Por lo tanto, debemos prestar atención a estas características, ya que pueden introducir mucho ruido en nuestro modelo y, por lo tanto, hacerlo menos exacto.

Con un análisis de ambos podemos evaluar el rendimiento del modelo.

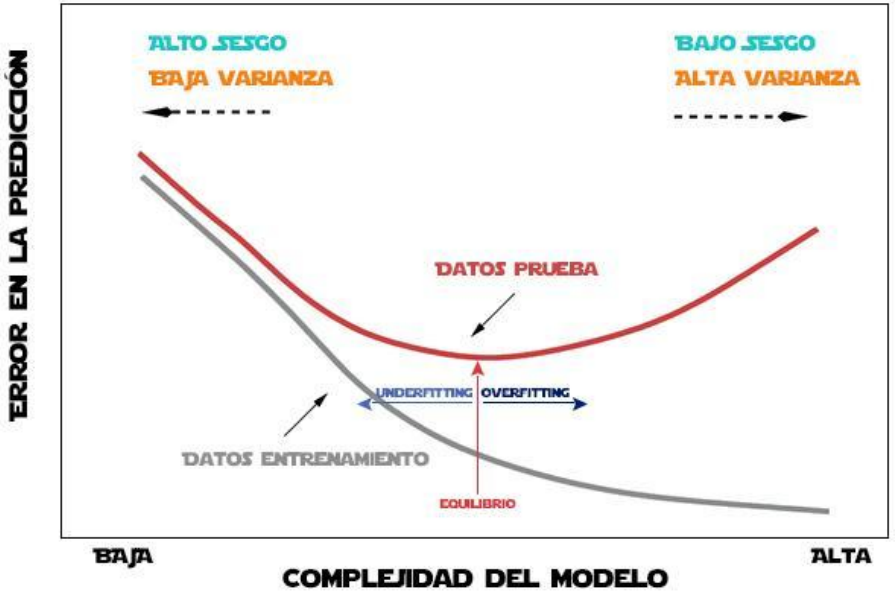
Comprender el bias y la varianza es fundamental para comprender el comportamiento de los modelos de predicción, pero en general lo que realmente importa es el **error general**, no la descomposición específica. **El punto ideal para cualquier modelo es el nivel de complejidad en el que el aumento en el bias es equivalente a la reducción en la varianza.**



Sesgo y Varianza

En el gráfico, si nos movemos de izquierda a derecha:

- Aumenta la complejidad del modelo
- Baja el sesgo y aumenta la varianza.
- Hasta que llega un momento en el que el error en los datos de test empieza a aumentar mientras que el de entrenamiento sigue disminuyendo. **Ese punto mínimo de error en los datos de test nos indica el nivel de complejidad óptimo para nuestro modelo.**



Sesgo y Varianza

Conclusiones:

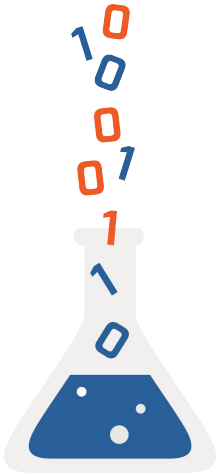
- **Modelo sesgado:** No logra capturar la forma de los datos. En general, tiene desempeño muy similar en el set de entrenamiento y de validación. Asociado al underfitting.
- **Modelo con mucha varianza:** Demasiado ajustado a los datos. Tiene desempeño muy bueno en el set de entrenamiento y malo en el de validación. Asociado al overfitting.
- **Curva de validación/complejidad:** Score en función de la complejidad. Sirve para ver regiones de baja complejidad (sesgo, underfitting) y demasiada complejidad (alta varianza, overfitting)
- **Curva de aprendizaje:** Score en función de la cantidad de datos. Sirve para ver, dado un modelo fijo, cómo reacciona a distintos tamaño del dataset. En particular, útil para diagnosticar alta varianza o modelo muy complejo (dado el tamaño de nuestro dataset).

Sesgo y Varianza

Enlaces recomendados:

- https://medium.com/appliedai-de/bias-variance-e4502eb4ad5
- https://elitedatascience.com/bias-variance-tradeoff





Lab Time!

¡Muchas gracias!

¡Sigamos trabajando!